



VILNIAUS UNIVERSITETAS
MATEMATIKOS IR INFORMATIKOS FAKULTETAS
DUOMENŲ MOKSLO STUDIJŲ PROGRAMA

Bakalauro baigiamasis darbas

**Triukšmui atsparus AM radijo kalbos atpažinimo
modelis su maršrutizavimu sąlygotais LoRA adapteriais**

**A Noise-Robust Speech Recognition Model for AM Radio with
Routing-Conditioned LoRA Adapters**

Rokas Sabaitis

Darbo vadovas : Tadas Danielius, Asist., Dr.

Vilnius
2026

Santrauka

Šiame darbe sukurta hibridinė sistema, skirta automatiniam kalbos atpažinimui (ASR) aviaciniuose aukšto dažnio (VHF) radijo ryšiuose. Darbe pristatoma nauja metodologija, jungianti ECAPA-TDNN klasifikavimo modelį, naudojamą kaip garso maršrutizavimo komponentą, bei keturis skirtingus Whisper-small LoRA adapterius, pritaikytus specifinėms trikdžių pseudožymėms. Tokia architektūra leidžia net santykinai mažam modeliui pasiekti gana aukštą transkribavimo tikslumą. Lyginant su baziniais Whisper-small ir Whisper-large modeliais bei nesąlyginiu LoRA adapteriu, pasiūlyta sistema pasiekė atitinkamai 77 %, 66,65 % ir 5,76 % žodžių klaidos rodiklio (WER) pagerėjimą. Lyginant su esamais specializuotais modeliais, sukurtas modelis atsilieka tik 9,78 % punkto, tačiau yra 6,4 karto mažesnis. Taip pat darbo metu buvo sukurta metodologija, leidžianti sintetinti aukšto dažnio radijo (VHF AM) amplitudinės moduliacijos duomenis naudojant atvirojo kodo principais paremtus įrankius.

Raktiniai žodžiai: Kalbos atpažinimas, Radijo ryšiai, Mašininis mokymasis, LoRA adapteriai, VHF ATC.

Summary

This work presents a hybrid system for automatic speech recognition (ASR) in aviation very high frequency (VHF) radio communications. A novel methodology is introduced, combining an ECAPA-TDNN classification model used as an audio routing component with four distinct Whisper-Small LoRA adapters, each conditioned on specific noise pseudo-labels. This architecture allows even a relatively small model to achieve competitive transcription accuracy. Compared to the baseline Whisper-Small, Whisper-Large models, and a non-conditional LoRA adapter, the proposed system achieved word error rate (WER) reductions of 77 %, 66.65 %, and 5.76 % respectively. Compared to existing specialized models, the proposed system trails by only 9.78 % points while being 6.4 times smaller. Additionally, a methodology for synthesizing VHF amplitude modulation (VHF AM) radio data using open-source tools was developed.

Keywords: Speech Recognition, Radio Communications, Machine Learning, LoRA Adapters, VHF ATC.

Turinys

Santrauka	2
Summary	3
Iliustracijų sąrašas	5
Lentelių sąrašas	6
Sutrumpinimai	7
Išvadas	8
1. Literatūros apžvalga	9
2. Duomenys	12
2.1. Anotuoti duomenys	12
2.2. Neanotuoti duomenys	13
2.3. Duomenų sintezė	14
2.3.1. Siųstuvo grandinė	16
2.3.2. Imtuvo grandinė	17
2.3.3. Stochastiškai parinkti parametrai	18
2.3.4. Galutiniai duomenų rinkiniai	20
2.4. Duomenų analizė	21
3. Metodologija	32
3.1. Trukdžių klasifikavimas	32
3.2. LoRA adapteriai	33
3.3. Žodžio klaidos metrika	34
4. Tiriamoji analizė	35
4.1. Trukdžių klasifikavimas	35
4.2. LoRA Adapteriai	36
5. Išvados ir rekomendacijos	40
6. Priedas	44
6.1. Dirbtinio intelekto naudojimas darbe	44
6.2. Trukdžių Klasifikavimas	44
6.3. LoRA Adapteriai	45

Iliustracijų sąrašas

1	Simuliacinio GNU Radio VHF AM siųstuvo blokinė diagrama.	15
2	Simuliacinio GNU Radio VHF AM imtuvo blokinė diagrama.	15
3	LiveATC pavyzdinių įrašų Mel spektrogramų grafikas.	22
4	UWB-ATCC ir ATCO2 pavyzdinių įrašų Mel spektrogramų grafikas.	23
5	UWB-ATCC, ATCO2 ir LiveATC įrašų PCA ir t-SNE klasterių diagramos.	24
6	UWB-ATCC, ATCO2 ir LiveATC įrašų RMS energijos bei dinaminio diapazono stačiakampės diagramos.	25
7	UWB-ATCC, ATCO2 ir LiveATC įrašų nulinio kirtimo dažnio stačiakampės diagramos. . .	25
8	UWB-ATCC, ATCO2 ir LiveATC įrašų spektrinių požymių diagramos.	26
9	Sintetintų pavyzdinių įrašų Mel spektrogramų diagramos.	27
10	Sintetintų ir tikrų įrašų PCA ir t-SNE klasterių diagramos.	28
11	Sintetintų ir tikrų įrašų RMS energijos bei dinaminio diapazono stačiakampės diagramos.	28
12	Sintetintų ir tikrų įrašų nulinio kirtimo dažnio stačiakampės diagramos.	29
13	Sintetintų ir tikrų įrašų spektrinių požymių diagramos.	29
14	Sintetintų ir tikrų įrašų PCA ir t-SNE klasterių diagramos pagal kokybes klases.	30
15	Sintetintų ir tikrų įrašų RMS energijos bei dinaminio diapazono stačiakampės diagramos pagal kokybės klases.	30
16	Sintetintų ir tikrų įrašų nulinio kirtimo dažnio stačiakampės diagramos pagal kokybės klases.	31
17	Sintetintų ir tikrų įrašų spektrinių požymių diagramos pagal kokybės klases.	31
18	Trukdžių kategorijų klasifikavimo modelių mokymo ir validavimo nuostolių bei tikslumo grafikai.	45
19	Tobulos trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.	45
20	Geros trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.	46
21	Vidutinės trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.	46
22	Blogos trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.	46

Lentelių sąrašas

1	jacktol/atc-dataset korpuso trukmės statistika pagal duomenų poaibius.	12
2	LibriSpeech korpuso trukmės statistika pagal duomenų poaibius.	13
3	ESC-50 ir LiveATC poaibių trukmės statistika.	14
4	VHF AM simuliacijos kanalo parametrai pagal įrašo kokybės klasę.	19
5	Fiksuotos daugiakelio kanalo atšakų konfigūracijos pagal įrašo kokybės klasę.	20
6	Treniravimo, validavimo ir testavimo poaibių trukmės statistika.	21
7	Įrašo kokybės klasių paskirstymas treniravimo, validavimo ir testavimo poaibiuose. .	21
8	Vertintų klasifikavimo architektūrų santrauka.	33
9	Klasifikavimo modelių suvestinė.	35
10	ECAPA-TDNN klasifikavimo ataskaita	35
11	ECAPA-TDNN klasifikavimo rezultatai realiuose ATC įrašuose.	36
12	Bazinių modelių žodžių klaidos dažnis (WER) pagal duomenų rinkinį.	37
13	Whisper Small + sąl. LoRA adapteriai: WER pagal kokybės klasę.	37
14	Lyginamieji modeliai ATC ASR testavimo rinkinyje (813 imčių).	38
15	Sąlyginių LoRA adapterių WER rodikliai pagal garso kokybės klasę mažoje testavimo imtyje.	39
16	Lyginamieji modeliai mažame testavimo rinkinyje (33 imtys).	39
17	CNN klasifikavimo ataskaita.	44
18	CRNN klasifikavimo ataskaita.	45
19	Whisper Small + nesąl. LoRA adapteris: WER pagal kokybės klasę.	47

Sutrumpinimai

- **WER** — žodžių klaidos rodiklis (angl. Word Error Rate)
- **ASR** — automatinis kalbos atpažinimas (angl. Automatic Speech Recognition)
- **VHF** — labai aukštas dažnis (angl. Very High Frequency)
- **AM** — amplitudinė moduliacija (angl. Amplitude Modulation)
- **LoRA** — žemo rango adaptacija (angl. Low-Rank Adaptation)
- **PEFT** — parametrų požiūriu efektyvus papildomas apmokymas (angl. Parameter-Efficient Fine-Tuning)
- **SDR** — programiškai apibrėžtas radijas (angl. Software Defined Radio)
- **AWGN** — adityvusis baltasis Gauso triukšmas (angl. Additive White Gaussian Noise)
- **FIR** — baigtinio impulso atsako filtras (angl. Finite Impulse Response)
- **IIR** — begalinio impulso atsako filtras (angl. Infinite Impulse Response)
- **AGC** — automatinis stiprinimo valdymas (angl. Automatic Gain Control)
- **DSB-FC** — dviguba šoninė juosta su pilnu nešliu (angl. Double Sideband Full Carrier)
- **ZCR** — nulinių perėjimų dažnis (angl. Zero Crossing Rate)
- **PCA** — pagrindinių komponentų analizė (angl. Principal Component Analysis)
- **ATC** — oro eismo valdymas (angl. Air Traffic Control)
- **GNU Radio** — atvirojo kodo programiškai apibrėžto radijo kūrimo sistema
- **OOD** — už mokymo duomenų pasiskirstymo ribų (angl. Out-of-Distribution)
- **RMS** — kvadratinis vidurkis (angl. Root Mean Square)
- **MFCC** — Mel dažnių keptriniai koeficientai (angl. Mel-Frequency Cepstral Coefficients)
- **E2E** — nuo galo iki galo metodas (angl. End-to-End)
- **WSSUS** — plačiąja prasme stacionarus nekoreliuotos sklaidos kanalas (angl. Wide-Sense Stationary Uncorrelated Scattering)
- **RFML** — radijo dažnių mašininis mokymasis (angl. Radio Frequency Machine Learning)

Ivadas

Aktualumas

Šiame darbe nagrinėjama kalbos atpažinimas radijo ryšių komunikacijos kontekste, ypatingą dėmesį skiriant labai aukštų dažnių (angl. Very High Frequency, toliau VHF) spektro komunikacijai. Vieni dažniausių VHF radijo ryšio prietaisų taikymo atvejų apima jūrinę, oras-oras bei oras-žemė komunikaciją. VHF imtuvai ir siųstuvai naudojami ryšiui tarp eismo dalyvių palaikyti, svarbiai saugumo informacijai perduoti bei pagalbos signalams (SOS) siųsti ekstremalių situacijų metu. Šie prietaisai yra esminiai užtikrinant saugumą tiek jūroje, tiek ore.

Nepaisant to, kad ši informacija gali būti santykinai lengvai pasiekama naudojant nebrangius imtuvus, jos automatinis transkribavimas į tekstą išlieka sudėtingu uždaviniu. Tai lemia įvairūs veiksniai, tokie kaip stiprūs trukdžiai, demoduliacijos metu prarandama informacija bei kiti signalo apdorojimo ypatumai. Aukšto patikimumo radijo ryšio transkribavimo sistemos galėtų reikšmingai prisidėti prie saugos tarnybų veiklos efektyvumo, sudarydamos galimybes greičiau reaguoti į nelaimės atvejus ir užtikrinti lengvai prieinamą bei aiškiai suprantamą informaciją apie radijo ryšio kanalais perduodamus pranešimus.

Tikslas

Sukurti LoRA adapteriais ir klasifikavimo modeliais paremtą sistemą, skirtą kalbos atpažinimui VHF aviacinės komunikacijos signaluose.

Uždaviniai

1. Atlikti aktualios literatūros analizę bei susipažinti su nagrinėjamos srities specifika.
2. Atlikti VHF degradaciją imituojančią duomenų sintezę, naudojant fizikiniais principais paremtą sistemą.
3. Apmokyti degradacijos pseudožymių klasifikavimo modelį, skirtą maršrutizuoti garso signalą į atitinkamą LoRA adapterį.
4. Apmokyti atskirą LoRA adapterį kiekvienai degradacijos pseudožymei.
5. Aprašyti atliktus darbus ir rezultatus.

1. Literatūros apžvalga

Civilinėje aviacijoje komunikacija tarp oro eismo dalyvių daugiausia vyksta naudojant AM pagrįstą VHF radijo ryšį. Ši komunikacijos sistema yra standartizuota ir prižiūrima Tarptautinės civilinės aviacijos organizacijos (ICAO), o jos pagrindiniai veikimo principai iš esmės nepasikeitė nuo XX a. vidurio. Aviacijoje naudojamas 118-137 MHz dažnių diapazonas [11], suskirstytas į 25 kHz kanalus, o Europoje – į tankesnius 8,33 kHz kanalus, siekiant efektyviau išnaudoti ribotą radijo spektrą [13].

AM ryšio technologija perduoda informaciją moduluojant nešančiosios bangos amplitudę, todėl tokio tipo ryšys yra jautrus įvairiems trukdžiams ir pašaliniais garsams, kurie gali paveikti signalo amplitudę ir taip iškraipyti informaciją. Triukšmą gali sukelti tiek natūralūs reiškiniai, tokie kaip atmosferinės iškrovos, tiek žmogaus sukurti šaltiniai: elektros įrangos veikimas, mechaninės vibracijos ar elektromagnetiniai trukdžiai [12]. Nepaisant šių trūkumų, AM ryšys išlieka plačiai naudojamas aviacijoje dėl kelių esminių savybių. Viena iš jų – galimybė vienu metu girdėti kelis persidengiančius signalus. Skirtingai nei dažninės moduliacijos (FM) sistemose, kuriose pasireiškia vadinamasis pagavimo efektas (angl. capture effect), kai stipresnis signalas visiškai nustelbia silpnesnį, AM ryšyje abu signalai išlieka girdimi [21, 23]. Tai ypač svarbu aviacijoje, nes tai leidžia pilotams ir dispečeriams pastebėti galimai persidengiančias transliacijas. Be to, AM ryšys efektyviau veikia didesniais atstumais ir esant silpnesniam signalui, todėl iki šiol yra naudojamas saugai kritinėse sistemose [13].

Dėl nuolatinių triukšmo ir signalo kokybės problemų aviacijos komunikacijoje taikomos griežtai standartizuotos procedūros bei frazeologija. Vienas pagrindinių komunikacijos elementų yra šaukiniai (angl. callsigns), naudojami kaip pagrindinis oro eismo valdymo komunikacijos identifikavimo mechanizmas. ICAO dokumente Doc 9432 [10] apibrėžiami trys pagrindiniai šaukinių tipai: orlaivio registracijos ženklas (pvz., G-ABCD), radiotelefoninis identifikatorius kartu su registracijos simboliais (pvz., FASTAIR CD) bei radiotelefoninis identifikatorius kartu su skrydžio numeriu (pvz., SPEEDBIRD 345). Pastarasis formatas naudojamas praktiškai visose komercinėse aviacijos operacijose.

Komunikacija tarp oro eismo valdymo dispečerių ir pilotų yra griežtai struktūrizuota bei asimetriška. Dispečeriai teikia leidimus, kursų, aukščio ir sekos nurodymus, o pilotai privalo pažodžiui pakartoti saugai kritinius komunikacijos elementus. Toks pakartojimo/išklausymo (angl. readback/hearback) principas leidžia dispečeriui aptikti ir ištaisyti klaidas prieš joms sukeltiant pavojingas situacijas [10, 11]. Šio proceso svarbą iliustruoja 1977 m. Tenerifės oro uosto katastrofa – daugiausia aukų pareikalavęs incidentas civilinės aviacijos istorijoje. Viena iš nelaimės priežasčių buvo nestandartinės frazės „we are now at take-off“ vartojimas vietoje ICAO nustatytos frazeologijos, dėl ko kilo klaidinga komunikacijos interpretacija [26].

Tyrimai rodo, kad pakartojimo klaidos sudaro apie 1-4 % visos piloto ir dispečerio komunikacijos [8]. Nors toks klaidų dažnis yra santykinai nedidelis, galimos pasekmės yra itin reikšmingos. Dėl šios priežasties pastaraisiais metais didelis dėmesys skiriamas automatizuoto kalbos atpažinimo (ASR) sistemoms, kurios galėtų padėti aptikti komunikacijos neatitikimus bei sumažinti žmogiškųjų klaidų riziką [29].

Šiame darbe modeliuoti keturi pagrindiniai degradacijos šaltiniai: (1) pridėtinis baltasis triukšmas (toliau AWGN), (2) impulsiniai trukdžiai, (3) Reilio slopinimas ir (4) Riso slopinimas. AWGN mo-

delis apibūdina šiluminį imtuvo triukšmą tiesioginio matomumo sąlygomis [21, 23]. Impulsiniai trukdžiai, kylantys dėl orlaivio elektronikos, atmosferinių išlydžių ir gretimkanalės interferencijos, modeliuojami naudojant Middletono A klasės modelį [12, 16]. Kai nėra dominuojančio tiesioginio sklaidimo kelio, signalas seka Reilio skirstinį [23], o orlaivio judėjimas sukelia Doplerio efektą bei fazinius iškreipimus [1]. Maršrutinio skrydžio metu, kai vyrauja tiesioginio matomumo komponentas kartu su daugiakelio sklaidimo efektais, signalas aprašomas Riso slopinimo modeliu, parametrizuojamu K faktoriumi [7, 13].

Dėl specifinių VHF radijo ryšio sąlygų oro eismo valdymo komunikacijos transkribavimas yra gerokai sudėtingesnis nei kitose kalbos atpažinimo srityse. Ryšio kokybę dažnai pablogina triukšmas, interferencija ir signalo slopinimas, todėl net žmogui ne visada aišku, kas yra sakoma [14]. Tokių įrašų transkribavimas reikalauja patyrusių specialistų, ilgą laiką dirbančių su radijo ryšio komunikacija, todėl duomenų rinkinių kūrimas yra brangus ir ribotas procesas. Dėl šios priežasties viešai prieinamų anotuotų ATC duomenų kiekis išlieka labai mažas. Didžiausias viešai prieinamas rankiniu būdu transkribuotas korpusas sudaro keturias valandas įrašų [32]. Todėl dauguma šiuolaikinių ATC kalbos atpažinimo tyrimų remiasi ribotais realiais duomenimis arba sintetinių duomenų generavimu [29]. Šiame darbe naudoti trys pagrindiniai realių ATC radijo ryšio įrašų duomenų rinkiniai: ATCO2, UWB-ATCC ir LiveATC poaibis. Taip pat naudoti du bendros paskirties kalbos ir garso duomenų rinkiniai: LibriSpeech ir ESC-50.

ATCO2 korpusas [32], sukurtas vykdant ES Horizon 2020 CleanSky projektą, yra išsamiausias viešai prieinamas ATC kalbos atpažinimo duomenų rinkinys. Jo testavimo dalį sudaro keturios valandos realių VHF radijo ryšio įrašų su rankiniu būdu parengtomis transkripcijomis. Šis rinkinys šiame darbe naudotas kaip pagrindinis vertinimo duomenų šaltinis.

UWB-ATCC korpusą sudaro apie 20 valandų rankiniu būdu transkribuotų ATC ryšio įrašų, surinktų Čekijos oro erdvėje [31]. Duomenys apima antžeminio valdymo komunikaciją bei turi kalbėtojo rolių žymas. Papildomi neanotuoti ATC garso duomenys buvo surinkti iš LiveATC [15], viešos platformos, talpinančios tiesioginius ir archyvinius VHF radijo srautus. Kadangi šie įrašai gaunami tiesiogiai iš VHF-AM ryšio kanalo be jokio papildomo apdorojimo, jie gerai atspindi realią ATC akustinę aplinką.

LibriSpeech [19] yra maždaug 1000 valandų trukmės anglų kalbos skaitytos kalbos korpusas, sudarytas iš LibriVox audioknygų įrašų. Šis rinkinys plačiai naudojamas ASR tyrimuose ir buvo vienas iš duomenų šaltinių, naudotų apmokant Whisper modelį [22]. ESC-50 [20] yra aplinkos garsų duomenų rinkinys, sudarytas iš 2000 įrašų 50 skirtingų garso klasių kategorijose. Šiame darbe naudota tik nedidelė jo dalis, remiantis „Calm-Whisper“ [28] straipsnio metodika.

Kadangi realių ATC duomenų kiekis nėra pakankamas efektyviam modelių apmokymui, šiame darbe papildomai remtasi radijo ryšio mašininio mokymosi (toliau RFML) srities metodais. Dauguma RFML duomenų rinkinių, pavyzdžiui, RadioML 2016.10a ir RadioML 2018.01A [3, 18], pateikiami I/Q signalų forma, o ne demoduluoto garso pavidalu. Tačiau šiame darbe buvo pritaikyta analogiška duomenų generavimo metodika, sintetinei duomenų aibei sudaryti naudojant GNU Radio pagrįstą simuliacijos grandinę. Remiantis šiuo principu, buvo sukurta sintetinė VHF radijo ryšio komunikacijos duomenų aibė. Siekiant modeliuoti skirtingo lygio degraduotą radijo ryšį, buvo sujungti Lib-

riSpeech [19] ir ESC-50 [20] duomenų rinkiniai, sudarant keturių lygių komunikacijos degradacijos scenarijus.

Pilnas E2E modelio apmokymas reikalauja didelių skaičiavimo resursų ir, esant ribotam specializuotų sričių duomenų kiekiui, dažnai nėra būtinas adaptacijai. Parametrų požiūriu efektyvus pritaikymas (PEFT) sprendžia šią problemą užšaldydamas iš anksto apmokytą bazinį modelį ir įvesdamas nedidelį kiekį papildomų apmokomų parametrų. Tokiu būdu išsaugomos bendrosios akustinės reprezentacijos, kartu perimant specifines srities charakteristikas. Houlsby et. al., 2019 [9] šį metodą formalizavo adapterių moduliais – kompaktiškais „bottleneck“ tinklais, integruotais į kiekvieną transformerio modelio sluoksnį – apmokant tik 3,6 % parametrų kiekvienai užduočiai ir išlaikant mažesnę nei 0,8 % našumo skirtumą, lyginant su pilnu modelio apmokymu GLUE rinkiniu. Papildomas LoRA metodo privalumas triukšmingomis sąlygomis yra žemo rango apribojimas, kuris sumažina modelio polinkį įsiminti triukšmingų žymų artefaktus ir taip veikia kaip reguliavimo mechanizmas prieš persimokymą [2].

VHF srityje LoRA metodas, taikomas Whisper modeliui, nėra plačiai paplitusi praktika, tačiau platesniame transformerių modelių kontekste jis plačiai naudojamas apmokytų modelių pritaikymui specifinėms sritims. Song et. al., 2024 [25] pateikia 18,5 % santykinį WER pagerėjimą daugiakalbiame kalbos atpažinime, naudojant kalbai specifinius LoRA modelius. Shi & Kawahara, 2024 [24] parodė, kad adapterių pritaikymas naudojant simuliuotus triukšmo duomenis pagerina sistemos veikimą triukšmingoje aplinkoje, o efektyviausi rezultatai pasiekiami adapterius integruojant į ankstyvuosius enkoderio sluoksnius. Wee et. al., 2025 [30] demonstravo, kad regioniškai specifinis Whisper modelio pritaikymas su triukšmu papildytais duomenimis pagerina transkripcijos tikslumą VHF aplinkoje, o didžiausias našumo nuosmukis pasireiškia dėl žodyno ir akcento neatitikimų, o ne akustinio modelavimo trūkumų — tai rodo, kad pritaikymo poreikis yra lokalizuotas dekoderio lygmenyje [5]. Remiantis šia įžvalga ir Shi & Kawahara, 2024 [24] rezultatais, šiame darbe pasirinktas analogiškas metodas: LoRA integruojamas į Whisper dekoderio kryžminio dėmesio sluoksnius, išlaikant užšaldytą enkoderį ir modelį apmokant su triukšmu papildytais GNU Radio simuliacijos grandinės duomenimis.¹

¹Toks užšaldyto enkoderio principas taip pat leidžia išvengti nesuderinamumo tarp HuggingFace PEFT LoRA realizacijos ir Whisper konvoliucinio log-mel spektrogramų enkoderio, dėl kurio tiesioginis LoRA pritaikymas enkoderio dalyje nėra galimas be papildomų bibliotekos struktūros modifikacijų. [27]

2. Duomenys

Šiame darbe naudoti penki duomenų rinkiniai: ATCO2, UWB-ATCC, LiveATC poaibis, LibriSpeech ir ESC-50. Jie priklauso dviem skirtingoms sritims: specializuotiems oro eismo kontrolės komunikacijos korpusams ir bendros paskirties kalbos bei garso atpažinimo duomenų rinkiniams. Atitinkamai, eksperimentiniai duomenys suskirstyti į dvi pagrindines kategorijas: anotuotus ir neanotuotus duomenis.

2.1. Anotuoti duomenys

Anotuotą duomenų dalį sudaro ATCO2, UWB-ATCC, LibriSpeech rinkiniai bei labai mažas LiveATC duomenų poaibis anotuotas ranka darbo metu. ATCO2 ir UWB-ATCC korpusai rinkiniai atspindi realias operacines VHF aplinkas ir pasižymi būdingomis VHF radijo ryšio kalbos akustinėmis savybėmis: siaurajuosčiu dažniniu atsaku (apie 300-3 400 Hz), kurį lemia analoginis AM perdavimo kanalas, kintančiu signalo ir triukšmo santykiu, nevietinių anglų kalbos vartotojų akcentais bei ICAO frazeologijos standartais apibūdintu specializuotu žodynu.

Abiejuose rinkiniuose garsas pateikiamas vieno kanalo, 16 bitų PCM formatu, naudojant 8 kHz diskretizacijos dažnį, atitinkantį efektyvią radijo ryšio kanalo dažninę juostą. Pagrindinis skirtumas tarp rinkinių yra įrašymo infrastruktūra: ATCO2 duomenys surinkti naudojant savanorių eksploatuojamus vartotojiško lygio SDR imtuvais, o UWB-ATCC įrašytas institucinės klasės įranga, todėl pasižymi aukštesne garso kokybe. Abu duomenų rinkiniai buvo pasiekti per viešai prieinamą HuggingFace duomenų rinkinį `jacktol/atc-dataset`, kuriame pateikiami iš anksto suskirstyti mokymo, validacijos ir testavimo poaibiai, apjungiantys abu korpusus. Rinkiniams jau buvo pritaikytas bazinis išankstinis apdorojimas: segmentavimas pagal laiko žymas, transkripcijų konvertavimas į didžiąsias raides, skaitmenų pavertimas žodžiais (pvz., *3 5 0* → *THREE FIVE ZERO*), raidžių konvertavimas į ICAO fonetinės abėcėlės atitikmenis (pvz., *N* → *NOVEMBER*), neangliškų, nesuprantamų segmentų pašalinimas, Unicode normalizacija bei rankinis žemos kokybės pavyzdžių filtravimas.

Kadangi pilnas ATCO2 korpusas platinamas pagal komercinę licenciją, šiame darbe naudotas tik viešai prieinamas vienos valandos profesionaliai anotuotas (angl. *gold-standard*) poaibis. Galutinė duomenų rinkinio statistika pateikiama lentelėje 1.

1 lentelė. *jacktol/atc-dataset* korpuso trukmės statistika pagal duomenų poaibius.

Statistika	Mokymo	Validavimo	Testavimo
Įrašų skaičius	6497	812	813
Bendra trukmė (val.)	5,90	0,75	0,76
Vidutinė įrašo trukmė (s)	3,27	3,31	3,37
Standartinis nuokrypis (s)	1,73	1,68	1,76
Minimali trukmė (s)	0,33	0,34	0,40
Mediana (s)	3,03	3,11	3,14
Maksimali trukmė (s)	15,27	9,34	8,75

Kaip aptarta literatūros apžvalgoje, LibriSpeech [19] yra plačiai naudojamas duomenų rinkinys kalbos atpažinimo tyrimuose ir vienas iš Whisper modelių šeimos apmokymo duomenų šaltinių [22]. Kadangi Whisper modelis jau buvo apmokytas naudojant šį rinkinį, jo naudojimas originalia forma modeliui nesuteiktų reikšmingos naujos lingvistinės informacijos. Tačiau transformuojant šį duomenų rinkinį į radijo ryšio signalą imituojančią formą, modelis gali būti pritaikytas specifinėms triukšmo ir signalo degradacijos charakteristikoms modeliuoti. Todėl maždaug 70 valandų LibriSpeech mokymo poaibis, kartu su iš anksto atskirtais validavimo ir testavimo poaibiais, buvo naudojamas kaip švarios kalbos šaltinis sintetinei akustinių duomenų generacijai. Sintezės proceso tikslas buvo imituoti VHF AM radijo ryšio akustines savybes, būdingas realioms oro eismo kontrolės perdavimo sąlygoms, įskaitant siaurajuostį dažninį atsaką, foninį triukšmą ir ryšio kanalo sukeltus iškraipymus. Duomenų sintezė buvo įgyvendinta naudojant GNU Radio principais paremtą simuliacijos sistemą. Galutinė duomenų rinkinio statistika pateikiama lentelėje 2.

2 lentelė. LibriSpeech korpuso trukmės statistika pagal duomenų poaibius.

Statistika	Mokymo	Validavimo	Testavimo
Įrašų skaičius	19 372	5 567	5 559
Bendra trukmė (val.)	68,35	10,51	10,75
Vidutinė įrašo trukmė (s)	12,70	6,80	6,96
Standartinis nuokrypis (s)	3,56	4,52	4,80
Minimali trukmė (s)	1,41	1,07	1,25
Mediana (s)	14,01	5,53	5,46
Maksimali trukmė (s)	19,99	35,16	34,96

2.2. Neanotuoti duomenys

Neanotuotą eksperimentinių duomenų dalį sudaro du šaltiniai: aplinkos garsų korpusas ESC-50 ir LiveATC platformos įrašų poaibis.

ESC-50 duomenų rinkinys [20] yra plačiai naudojamas duomenų rinkinys, skirtas nekalbinių aplinkos garsų klasifikavimui. Jį sudaro 2 000 penkių sekundžių trukmės įrašų, suskirstytų į 50 akustinių kategorijų, apimančių biologinius, mechaninius ir miesto aplinkos garsus. Šiame darbe iš ESC-50 buvo atrinkti 144 garso įrašai (apie 12 minučių), kuriems pritaikyta tokia pati VHF radijo ryšio kanalo sintezės procedūra kaip ir LibriSpeech duomenims. Sugeneruoti nekalbiniai segmentai nedidele proporcija buvo įtraukti į mokymo duomenų rinkinį. Toks metodas pasirinktas remiantis Whisper [22] ir Calm-Whisper [28] tyrimų rezultatais, rodančiais, kad nedidelio kiekio nekalbinio garso įtraukimas į mokymo duomenis reikšmingai sumažina modelio haliucinacijų dažnį, beveik nepaveikdamas žodžių klaidų rodiklio (WER). Be to, vienoda penkių sekundžių trukmė visuose ESC-50 įrašuose supaprastino jų integraciją į sintezės grandinę, nes nereikėjo papildomo segmentavimo.

Neanotuotų VHF įrašų poaibis buvo paimtas iš HuggingFace platformoje prieinamo nyuuzyou/liveatc duomenų rinkinio [17], sudaryto remiantis LiveATC [15] platformos įrašais. LiveATC yra vieša platforma, agreguojanti tiesioginius ir archyvinus VHF radijo ryšio srautus, su-

rinktus savanorių naudojant programiškai apibrėžto radijo (SDR) imtuvus. Duomenų rinkinį sudaro apie 4 216 įrašų, apimančių daugiakalbę oro eismo kontrolės komunikaciją tarp pilotų ir dispečerių įvairiose oro erdvėse.

Šių įrašų akustinės savybės yra panašios į ATCO2 korpusą, nes abu duomenų šaltiniai buvo surinkti naudojant panašios klasės vartotojiško lygio SDR įrašymo grandines. Šis poaibis nebuvo tiesiogiai naudojamas kalbos atpažinimo modelių mokymui. Vietoje to, jis buvo naudojamas kaip tikslinės srities akustinis pavyzdys LibriSpeech sintezės procese. LiveATC įrašai kartu su ATCO2 ir UWB-ATCC korpusais suteikė empirines VHF AM radijo kanalo akustines charakteristikas, pagal kurias buvo parametrizuota GNU Radio pagrindu sukurta simuliacijos grandinė. Prieš naudojimą įrašai buvo suskaidyti į 30 sekundžių segmentus ir apdoroti pašalinant tylos intervalus, todėl gauta apie 34 valandos tinkamų naudoti garso duomenų, pateiktų lentelėje 3.

Be pagrindinių korpusų, į sintezės grandinę taip pat buvo įtraukti keturi trumpi komercinių orlaivių salono aplinkos garso įrašai, paimti iš Freesound platformos [6]. Įrašai apėmė propelerinius bei reaktyvinius orlaivius, taip padidinant simuliuojamo foninio triukšmo akustinę įvairovę. Šie įrašai atsitiktinai įmaišyti į duomenų augmentacijos procesą nedideliu garsumo lygiu, siekiant aproksimuoti piloto kabinai būdingą foninę akustinę aplinką, kuri dažnai degradoja pilotų perduodamą radijo ryšio signalą.

3 lentelė. ESC-50 ir LiveATC poaibių trukmės statistika.

Statistika	ESC-50	LiveATC
Įrašų skaičius	144	4 216
Bendra trukmė (val.)	0,20	34,37
Vidutinė įrašo trukmė (s)	5,00	29,35
Standartinis nuokrypis (s)	0,00	3,54
Minimali trukmė (s)	5,00	0,10
Mediana (s)	5,00	30,00
Maksimali trukmė (s)	5,00	30,00


2.3. Duomenų sintezė

Kaip minėta anksčiau, didelio masto anotuočių VHF kalbos duomenų trūkumas sudaro esminį apribojimą prižiūrimo mokymo kalbos atpažinimo modelių kūrimui šioje srityje. Siekiant iš dalies kompensuoti šį ribotumą, šiame darbe taikoma programinė VHF AM radijo ryšio simuliacija, skirta sintetinių mokymo duomenų generavimui, aproksimuojančiam realių VHF perdavimų akustines charakteristikas.


Aviacinis VHF ryšio kanalas yra plačiai naudojama perdavimo terpė, pasižyminti daugiakeliu signalo sklidimu, Doplerio poslinkiais, adityviniu triukšmu ir amplitudinės moduliacijos sukuriamais dažninės juostos apribojimais [1, 7]. Šie efektai degradoja perduodamos kalbos akustinę kokybę, tačiau gali būti pakankamai tiksliai modeliuojami signalų apdorojimo metodais. Viena svarbiausių VHF radijo komunikacijos savybių yra siaurajuostis dažninis filtras kuris naikina visą garsą žemiau 300 Hz

bei aukščiau 3 400 Hz. Dėl šios priežasties VHF radijo kalba reikšmingai skiriasi nuo plataus dažninio diapazono švarios kalbos, naudojamos bendruose kalbos atpažinimo modelių duomenų rinkiniuose, tokiuose kaip LibriSpeech [19]. Ankstesni tyrimai rodo, kad kalbos atpažinimo modeliai, iš anksto apmokyti naudojant švarią kalbą, įskaitant Whisper [22], ženkliai praranda tikslumą realioje VHF radijo ryšio aplinkoje, jei mokymo metu nebuvo susidurta su ryšio kanalo sukeltais iškraipymais [5, 29].

Šioms sąlygoms modeliuoti buvo naudojama GNU Radio sistema — atvirojo kodo įrankis, skirtas programiškai apibrėžto radijo (SDR) sistemų kūrimui. Visi signalų apdorojimo etapai, įskaitant moduliaciją, demoduliaciją, filtravimą ir ryšio kanalo simuliaciją, įgyvendinami programiškai, nenaudojant specializuotos radijo aparatūros. Dėl lankstumo ir galimybės kurti individualizuotas signalų apdorojimo grandines GNU Radio yra tinkama atkuriamai analoginių radijo kanalų poveikio kalbos signalams simuliacijai. VHF AM radijo ryšio siųstuvo (TX) ir imtuvo (RX) grandinės buvo realizuotos Python aplinkoje ir sujungtos į vientisą sintezės grandinę, skirtą radijo ryšio garso generavimui iš švarių kalbos signalų. Sintezės procedūroje naudoti šie duomenų rinkiniai: 68 valandų LibriSpeech mokymo poaibis, LibriSpeech validavimo ir testavimo poaibiai bei ESC-50 aplinkos garsų korpusas.



1 pav. Simuliacinio GNU Radio VHF AM siųstuvo blokinė diagrama.



2 pav. Simuliacinio GNU Radio VHF AM imtuvo blokinė diagrama.

Sintezės procesas vykdomas keliais etapais. Pirmiausia kiekvienas įvesties kalbos signalas sumaišomas su atsitiktinai parinktu foniniu aplinkos garso įrašu prieš taikant radijo ryšio kanalo modeliavimą. Foninių garsų bibliotekoje sukaupta apie penkias minutes įvairių orlaivio kabinos įrašų, įskaitant prietaisų skydelio triukšmą, reaktyvinių variklių kabinos foną ir propelerinių orlaivių vidaus

garsus, paimtus iš Freesound platformos [6]. Šie įrašai įtraukti siekiant, kad sintetinis duomenų rinkinys tiksliau atspindėtų realias piloto pusės VHF komunikacijos akustines sąlygas, kuriose kabinos foninis triukšmas nuolat veikia radijo signalą.

2.3.1. Siųstuvo grandinė

Siųstuvo grandinė įgyvendina siaurajuostę amplitudinės moduliacijos (AM) schemą, modeliuojančią VHF aeronautinio ryšio kanalą. Apdorojimo grandinė sudaryta iš signalų filtravimo, moduliacijos ir nuosekliai taikomų kanalo iškraipymų etapų.

Pirmiausia, sujungtas kalbos ir foninio triukšmo signalas apribojamas iki telefonijos dažnių juostos naudojant Kaiserio lango baigtinio impulso atsako (FIR) juostinį filtrą su 300-3 400 Hz praleidžiamąja juosta:

$$y[n] = \sum_{k=0}^{N-1} h[k] x[n-k] \quad (1)$$

kur $h[k]$ yra FIR filtro impulso atsakas, o $x[n]$ ir $y[n]$ atitinkamai žymi įėjimo ir išėjimo signalus. Filtras projektuojamas naudojant Kaiserio lango metodą, užtikrinant 80 dB slopinimą stabdymo juostoje.

Prieš moduliaciją signalas yra normalizuojamas iki fiksuoto RMS lygio 0,1, siekiant užtikrinti vienodą amplitudę visomis sąlygomis. Tuomet signalas diskretizuojamas iš 16 kHz į 240 kHz naudojant daugiafazį Kaiserio FIR filtrą ir moduluojamas taikant dvigubos šoninės juostos pilno nešlio (DSB-FC) amplitudinę moduliaciją:

$$s[n] = (1 + m \cdot x[n]) \cdot \cos\left(\frac{2\pi f_{IF}}{f_s} n\right) \quad (2)$$

kur m yra atsitiktinai parinktas moduliacijos indeksas, $f_{IF} = 10$ kHz yra tarpinis dažnis, o $f_s = 240$ kHz yra diskretizavimo dažnis.

Po moduliacijos radijo signalui nuosekliai taikomi kanalo iškraipymai. Pirmiausia modeliuojamas Reilio slopinimas, generuojant juostiniu filtru apribotą apvaskalą iš nepriklausomų Gauso I/Q triukšmo komponentų:

$$r[n] = (o_f + d_f \cdot e[n]) \cdot s[n] \quad (3)$$

kur $e[n]$ yra nulinio vidurkio ir vienetinės dispersijos Reilio apvaskalas, o_f žymi slopinimo poslinkį, o d_f - slopinimo gylį. Parametrai o_f ir d_f parenkami iš konkrečiai kanalo kokybės pakopai apibrėžtų stochastinių intervalų.

Toliau modeliuojamas dažniui selektyvus daugiakelis slopinimas, naudojant atšakų vėlinimo linijos FIR filtrą:

$$y[n] = \sum_{k=0}^{L-1} a_k r[n-k] \quad (4)$$

kur a_k yra atšakų svoriai, o L - atšakų skaičius, didėjantis kartu su kanalo degradacijos lygiu. Toks modelis atitinka Bello WSSUS kanalo sistemą [1].

Po daugiakelio slopinimo pridedamas kompleksinis adityvus baltasis Gauso triukšmas (AWGN):

$$y_{ch}[n] = y[n] + \sigma_n (n_I[n] + j n_Q[n]), \quad n_I, n_Q \sim \mathcal{N}(0,1) \quad (5)$$

kur σ_n yra triukšmo įtampos parametras, parenkamas iš konkrečiai sąlygai nustatytų intervalų.

Siekiant atspindėti realioms VHF radijo aplinkoms būdingus elektromagnetinius trikdžius, papildomai modeliuojamas impulsinis triukšmas:

$$y_{imp}[n] = y_{ch}[n] + \sum_{i=1}^{N_p} b_i \delta[n - n_i] \quad (6)$$

kur $b_i \sim \mathcal{U}(-A_{imp}, A_{imp})$ yra atsitiktinės impulsų amplitudės, o n_i - impulsų pozicijos diskrečiuose mėginiuose. Impulsų dažnis ir amplitudė A_{imp} priklauso nuo modeliuojamos kanalo būsenos. Nors impulsinis triukšmas nėra įtrauktas į [3, 18] naudojamus RFML kanalų modelius, jo buvimas VHF aplinkose yra gerai dokumentuotas [16] ir stebimas realiuose ATC įrašuose [32].

2.3.2. Imtuvo grandinė

Imtuvo grandinė demoduliuoja simuliuotą radijo signalą ir rekonstruoja garso išvestį, atitinkančią realių VHF AM imtuvų veikimą SDR pagrindu vykdomame ATC duomenų rinkime. Apdorojimo grandinė apima dažnio perkėlimą, demoduliaciją, stiprinimo valdymą bei po demoduliacijos atsirandančių artefaktų modeliavimą.

Pirmiausia gautas radijo signalas perkeliamas į bazinę dažnių juostą, dauginant jį iš kompleksinio demoduliacijos signalo tarpinio dažnio $f_{IF} = 10$ kHz srityje:

$$r_{bb}[n] = r_{RF}[n] \cdot e^{-j2\pi f_{IF}n/f_s} \quad (7)$$

kur $r_{RF}[n]$ yra gautas radijo signalas, diskretizuotas kvadratūriniu dažniu $f_s = 240$ kHz, o $r_{bb}[n]$ yra kompleksinis bazinės juostos signalas. Toliau signalas filtruojamas žemadažniu Kaiserio FIR filtru ir retinamas koeficientu $R = 6$ iki apdorojimo dažnio $f_c = f_s/R = 40$ kHz:

$$y[n] = \sum_{k=0}^{N-1} h_{lp}[k] r_{bb}[n - k] \quad (8)$$

Siekiant sumažinti triukšmą kanalo neaktyvumo metu, taikomas galios slenkstinis (angl. squelch) mechanizmas. Momentinė signalo galia apskaičiuojama naudojant pirmos eilės IIR glodinimą:

$$P[n] = \alpha P[n - 1] + (1 - \alpha) |y[n]|^2 \quad (9)$$

kur α yra glodinimo koeficientas. Kai $P[n] < T_c$, išvestis nustatoma į nulį, kur T_c yra konkrečiai sąlygai nustatytas slenkstis. Siekiant išvengti staigių perjungimo artefaktų, taikomas 75 ms išlaikymo intervalas.

AM demoduliacija atliekama nekoherentiniu būdu, naudojant apvalkalo detekciją:

$$y_{env}[n] = |y[n]| \quad (10)$$

Po demoduliacijos taikomas pirmos eilės IIR aukštadažnis filtras, pašalinantis AM nešlio sukeltą nuo-

latinę dedamąją:

$$y_{dc}[n] = y_{env}[n] - y_{env}[n-1] + \beta y_{dc}[n-1] \quad (11)$$

kur $\beta = 1 - 2\pi f_c^{HP} / f_c$, o ribinis dažnis $f_c^{HP} = 30$ Hz.

Toliau signalui taikomas lėto veikimo automatinio stiprinimo valdymas (AGC), normalizuojantis garsumo lygį ir išsaugantis kanalo sukeltus slopinimo pokyčius. Stiprinimo koeficientas apskaičiuojamas pagal:

$$g[n] = \min \left(\frac{0,25}{\sqrt{\max(P_{agc}[n], \varepsilon)}}, g_{max} \right) \quad (12)$$

kur $P_{agc}[n]$ yra glodintas galios įvertis su 300 ms laiko konstanta, $\varepsilon = 10^{-12}$ apsaugo nuo dalybos iš nulio, o $g_{max} = 4$ apriboja maksimalų stiprinimą ir sumažina triukšmo sustiprinimą tylos intervalais.

Siekiant tiksliau atkartoti realių VHF AM imtuvų savybes, papildomai modeliuojami po demoduliacijos atsirandantys artefaktai. Pirmiausia įterpiamas elektrinių impulsų triukšmas, atsirandantis dėl elektromagnetinių trukdžių ir perjungimo procesų:

$$y_{click}[n] = y_{AGC}[n] + \sum_{i=1}^{N_c} c_i \delta[n - n_i] + 0.3 c_i \delta[n - n_i - 1] \quad (13)$$

kur $c_i \sim \mathcal{U}(-A_c, A_c)$, o kiekvienas impulsas turi vieno mėginio slopinimo uodegą. Taip pat modeliuojami intermoduliaciniai tonai, atsirandantys dėl imtuvo netiesiškumų:

$$y_{art}[n] = y_{click}[n] + A_t [\sin(2\pi f_1 n / f_{sim}) + 0.6 \sin(2\pi f_2 n / f_{sim})] \quad (14)$$

kur f_1, f_2 ir A_t kiekvienam įrašui parenkami atsitiktinai iš konkrečiai sąlygai nustatytų intervalų.

Galiausiai signalas filtruojamas Kaiserio lango juostiniu filtru su 300-3 400 Hz praleidžiamąja juosta esant 8 kHz apdorojimo dažniui:

$$y_{out}[n] = \sum_{k=0}^{N-1} h_{bp}[k] y_{art}[n - k] \quad (15)$$

Šis etapas užtikrina, kad sintezuotas signalas spektriškai atitiktų realų ATC radijo garsą, įrašytą SDR imtuvais, bei išlaikytų ATCO2 ir UWB-ATCC korpusams būdingą 300-3 400 Hz dažnių juostą ir 8 kHz diskretizavimo dažnį. Po visų apdorojimo etapų signalas papildomai perdiskretizuojamas į 16 kHz dažnį, siekiant atitikti Whisper modelio įvesties reikalavimus.

2.3.3. Stochastiškai parinkti parametrai

Simuliacijoje apibrėžiamos keturios diskrečios kanalo kokybės pseudožymės: (1) *tobulas*, (2) *geras*, (3) *vidutinis* ir (4) *blogas*. Šios žymės aprašo kanalo degradacijos spektrą - nuo idealaus tiesioginio matomumo ryšio iki stipriai iškraipyto signalo sklidimo. Kiekvienam įvesties įrašui visos keturios žymės generuojamos lygiagrečiai, todėl sukuriama keturi atitinkami išvesties garso įrašai.

Siekiant atspindėti realių ryšio kanalų kintamumą, kiekvienam įrašui kanalo parametrai nepri-

klausomai parenkami iš konkrečiai būsenai apibrėžtų tolygiųjų skirstinių:

$$p_i \sim \mathcal{U}(a_i, b_i), \quad \Theta = \{m, \sigma_n, d_f, f_D, \lambda, A, T_c\}. \quad (16)$$

Čia m žymi moduliacijos indeksą, σ_n - adityviojo baltojo Gauso triukšmo (AWGN) įtampos parametras, d_f - Reilio slopinimo gylį, f_D - slopinimo kitimo dažnį, λ - impulsinių trikdžių dažnį, A - artefaktų amplitudę, o T_c - *squelch* slenkstį.

Parametrų ribos parinktos taip, kad gretimos kokybės klasės iš dalies persidengtų, taip išlaikant tolydų kanalų degradacijos pobūdį, tačiau kartu užtikrinant pakankamą būsenų atskiriamumą. Daugiakelio kanalo atšakų geometrija a ir tarpinis dažnis f_{IF} yra fiksuojami kiekvienai kanalo būsenai.

4 lentelė. VHF AM simuliacijos kanalo parametrai pagal įrašo kokybės klasę.

Parametras	Tobulas	Geras	Vidutinis	Blogas
<i>Moduliacija</i>				
Moduliacijos indekso intervalas	[0,75; 0,92]	[0,60; 0,90]	[0,58; 0,85]	[0,40; 0,78]
<i>AWGN</i>				
Triukšmo įtampos intervalas	[0,005; 0,020]	[0,030; 0,080]	[0,065; 0,130]	[0,060; 0,110]
<i>Reilio slopinimas</i>				
Slopinimo kitimo dažnio intervalas (Hz)	[0,0; 0,5]	[0,3; 3,0]	[1,0; 6,0]	[3,0; 12,0]
Slopinimo gylio intervalas	[0,000; 0,020]	[0,030; 0,080]	[0,050; 0,110]	[0,080; 0,160]
Slopinimo poslinkio intervalas	[0,980; 1,000]	[0,900; 0,980]	[0,860; 0,960]	[0,760; 0,900]
<i>Impulsiniai trikdžiai</i>				
Amplitudės intervalas	[0,00; 0,20]	[0,30; 1,00]	[0,60; 1,20]	[1,00; 1,80]
Dažnio intervalas (impulsai/s)	[0; 50]	[100; 350]	[150; 450]	[350; 800]
<i>Postdemoduliacinis triukšmas</i>				
Spragtelėjimų dažnis (spragt./s)	—	[2; 10]	[5; 25]	[25; 80]
Spragtelėjimų amplitudės intervalas	—	[0,05; 0,15]	[0,08; 0,20]	[0,15; 0,35]
<i>Intermoduliaciniai tonai</i>				
Tonų lygio intervalas	—	—	[0,01; 0,04]	[0,03; 0,08]
Pirmojo tono dažnis (Hz)	—	—	[300; 500]	[300; 600]
Antrojo tono dažnis (Hz)	—	—	[600; 1200]	[400; 1500]
<i>Squelch</i>				
Slenkstis (dB)	-60	-60	-58	-55

5 lentelė. Fiksuotos daugiakelio kanalo atšakų konfigūracijos pagal įrašo kokybės klasę.

Atšakos indeksas ($\times 4,17 \mu s$ vėlinimas)	Tobulas	Geras	Vidutinis	Blogas
0 (0 μs)	1,00	1,00	1,00	1,00
1 (4,2 μs)	—	0,00	0,00	0,00
2 (8,3 μs)	—	0,00	0,09	0,00
3 (12,5 μs)	—	0,06	0,00	0,14
4 (16,7 μs)	—	0,00	0,00	0,00
5 (20,8 μs)	—	0,00	0,05	0,00
6 (25,0 μs)	—	0,00	0,00	0,00
7 (29,2 μs)	—	0,03	0,00	0,08
8 (33,3 μs)	—	—	0,00	0,00
9 (37,5 μs)	—	—	0,00	0,00
10 (41,7 μs)	—	—	0,00	0,00
11 (45,8 μs)	—	—	0,02	0,00
12 (50,0 μs)	—	—	—	0,00
13 (54,2 μs)	—	—	—	0,04
14–20 (58–83 μs)	—	—	—	0,00
21 (87,5 μs)	—	—	—	0,02
Nenulinės atšakos	0	2	3	4
Didžiausias vėlinimas (μs)	0	29,2	45,8	87,5

2.3.4. Galutiniai duomenų rinkiniai

Pritaikius VHF AM kanalo sintezės procedūrą LibriSpeech ir ESC-50 duomenų rinkiniams, gautas duomenų rinkinys susidaro iš apytiksliai 280 valandų garso mokymo poaibiui bei po maždaug 40 valandų validavimo ir testavimo poaibiams. Kadangi LoRA apmokymo procedūra nereikalauja daug duomenų bei atsižvelgiant į skaičiavimo resursų apribojimą mokymo poaibis buvo sumažintas iki 100 valandų. Duomenys buvo paimti iš pilnos duomenų aibės atsižvelgiant į keturių kanalo kokybės klasių skaičių. Kiekviena klasė buvo paskirstyta po lygiai, maždaug 25 valandų duomenų. Tuo tarpu validavimo ir testavimo duomenų rinkiniai buvo palikti pilnos apimties, kadangi pilnų vertinimo aibių išlaikymas užtikrina statistiškai patikimą ir reprezentatyvų modelio veikimo vertinimą.

Sintezės stochastiniai parametrai buvo iteratyviai derinami rankiniu būdu, siekiant suderinti sintetinto signalo akustines charakteristikas su tomis, kurios stebimos realiuose VHF radijo įrašuose iš ATCO2, UWB-ATCC ir LiveATC duomenų rinkinių. Visų sintetinto duomenų rinkinio dalių trukmės statistika pateikiama lentelėje 6, o klasių pasiskirstymas pagal kokybės sąlygas galima pamatyti lentelėje 7.

6 lentelė. Treniravimo, validavimo ir testavimo poaibių trukmės statistika.

Statistika	Treniravimo	Validavimo	Testavimo
Įrašų skaičius	28 345	22 268	22 236
Bendra trukmė (val.)	100,00	42,04	42,98
Vidutinė įrašo trukmė (s)	12,70	6,80	6,96
Standartinis nuokrypis (s)	3,56	4,52	4,80
Minimali trukmė (s)	1,41	1,07	1,25
Mediana (s)	14,01	5,53	5,46
Maksimali trukmė (s)	19,99	35,16	34,96

7 lentelė. Įrašo kokybės klasių paskirstymas treniravimo, validavimo ir testavimo poaibiuose.

Klasė	Treniravimo	Validavimo	Testavimo
Tobulas	7 068	5 567	5 559
Geras	7 056	5 567	5 559
Vidutinis	7 061	5 567	5 559
Blogas	7 160	5 567	5 559
Iš viso	28 345	22 268	22 236

2.4. Duomenų analizė

Duomenų analizei visi garso įrašai buvo konvertuoti į Mel spektrogramas, kurios atvaizduoja laiko ir dažnio reprezentaciją, koduojančią signalo galią decibelais. Nors E2E kalbos atpažinimo modeliai, tokie kaip Whisper, viduje naudoja log-Mel filtrų banko (angl. log-Mel filterbank) reprezentaciją [22], Mel spektrogramos buvo pasirinktos kaip pagrindinė šios analizės vizualizavimo priemonė dėl jų lengvesnės interpretacijos.


Pirmiausiai buvo analizuojami realus ATC garso įrašai (LiveATC, ATCO2 ir UWB-ATCC) siekiant nustatyti jų skirtumus bei bendras kalbos ir trukdžių charakteristikas. Nagrinėjant iš rinkinių atsitiktinai paimtų įrašų Mel spektrogramų diagramas 3 4, matome, kad garso įrašų akustinės charakteristikos stipriai skiriasi.

Įrašams, surinktų iš LiveATC duomenų rinkinio, būdinga ženkliai didesnis triukšmo lygis nei įrašams iš UWB-ATCC ir ATCO2 rinkinių. Tai galima būtų paaiškinti rinkimo metodologijos skirtumais, LiveATC duomenys buvo renkami savanorių valdomais SDR imtuvais, o UWB-ATCC buvo renkami kontroliuotoj aplinkoje. Labiausiai degradavusiuose pavyzdžiuose triukšmo lygis priartėja prie kalbos signalo lygio, taip užmaskuodamas fonetinį turinį. Be to, spektrogramose matomi impulsinio triukšmo artefaktai, tai yra trumpalaikiai plataus dažnių diapazono galios šuoliai, susiję su triukšmo slopinintuvo slenksčio perėjimais imtuvo grandinėje. Juos galima pastebėti kaip trumpus spektrogramos fragmentus tarp kalbos segmentų. Šie artefaktai atsiranda tuomet, kai trumpi pakankamos amplitudės


trukdžių signalai nėra atfiltruojami triukšmo slopinimo filtro (angl. squelch filter) ir įrašė užfiksuojami kaip trumpi girdimo garso impulsai.

Tuo tarpu ATCO2 ir UWB-ATCC įrašų spektrogramos nagrinėtuose pavyzdžiuose pasižymi gero-kai švaresniu garsu. Tai atspindi jų surinkimą labiau kontroliuojamomis sąlygomis, naudojant insti-tucinio lygio įrašymo infrastruktūrą. Nepaisant to, visame dažnių diapazone išlieka matomas žemo lygio triukšmo fonas, lydimas atsitiktinių siaurajuosčių galios šuolių tam tikruose dažnių intervaluose, kurie, nors ir subtilūs, vis tiek gali bloginti ASR modelių veikimą.

Taip pat verta paminėti, kad visuose trijuose duomenų rinkiniuose stebimas būdingas VHF AM radijo garso juostinis filtras, kuris spektrogramose matomas kaip laipsniškas signalo galios mažėjimas virš 3,4 kHz ir žemiau 300 Hz. Vis dėlto, kadangi tikslūs originalios įrašymo aparatūros filtrų paramet-rai ir langų konfigūracijos nėra žinomi, kai kuriuose įrašuose virš 3,4 kHz vis dar gali būti aptinkama tam tikra spektrinė energija. Šie artefaktai gali pasireikšti kaip žemo lygio triukšmas arba alijasavimo artefaktai.



3 pav. LiveATC pavyzdinių įrašų Mel spektrogramų grafikas.



4 pav. UWB-ATCC ir ATCO2 pavyzdinių įrašų Mel spektrogramų grafikas.

Po nedidelės kokybinės garso iškarpų analizės rankiniu būdu buvo atlikta kiekybinė analizė, iš kiekvieno duomenų rinkinio atsitiktinai atrenkant po 200 ilgesnių nei 5 sekundės pavyzdžių. Tuomet kiekvieno įrašo pirmosioms 5 sekundėms buvo apskaičiuotas akustinių rodiklių rinkinys. 5 sekundžių apribojimas analizėje buvo taikomas todėl, kad kalbos turinys patikimiausiai pasireiškia perdavimo pradžioje, o vėlesnėse ilgesnių įrašų dalyse dažniau aptinkami tylos segmentai. Todėl visi šiame skyriuje pateikiami statistiniai rodikliai apskaičiuoti naudojant šį fiksuotą 5 sekundžių segmentą.

Mel spektrogramų požymių erdvės analizei kiekvieno įrašo požymiai buvo sumažinti iki dviejų dimensijų naudojant tiek pagrindinių komponentų analizę (PCA), tiek t-SNE metodą, siekiant nustatyti bendrus požymių klasterius.

Analizuojant įrašų akustinius rodiklius, statistiniai rodikliai buvo suskirstyti į tris grupes:

1. Energijos srities statistikos:

- Vidutinė RMS energija.
- RMS standartinis nuokrypis.
- Dinaminis diapazonas decibelais.


2. Nulinių perėjimų dažnis (angl. zero crossing rate, ZCR).

3. Spektrinės statistikos:


- Spektrinis centroidas.
- Spektrinis plotis.

Nagrinėjant PCA ir t-SNE projekcijas LiveATC ir jungtinei ATCO2/UWB-ATCC grupei 5, matomas aiškus dviejų šaltinių pasiskirstymų atsiskyrimas. ATCO2/UWB-ATCC klasteris (pažymėtas raudonai) yra koncentruotas centrinėje PCA erdvės dalyje, tuo tarpu LiveATC įrašai (pažymėti mėlynai) plačiai išsidėstę visoje erdvėje. Kadangi PC1 paaiškina 88,9 % visos požymių erdvės dispersijos, šis atsiskyrimas palei PC1 atspindi fundamentalų skirtumą tarp abiejų šaltinių akustinių charakteristikų. Analizuojant t-SNE projekciją, kaip ir PCA atveju, taip pat matyti, kad abi grupės priklauso skirtingiems akustiniams pasiskirstymams. Kadangi LiveATC įrašai yra taip plačiai išsibarstę požymių erdvėje, galima teigti, kad jie pasižymi žymiai didesne akustine įvairove, kuri nėra reprezentuojama jungtiniame ATCO2/UWB-ATCC rinkinyje.

Tą patį galima pastebėti analizuojant energijos srities statistinius rodiklius 6. Grafikuose LiveATC pasižymi žymiai didesniu ir labiau išsisklaidžiusiu vidutinės RMS energijos pasiskirstymu (mediana apie 0,13, tarpkvartilinis diapazonas siekia 0,33), tuo tarpu ATCO2/UWB-ATCC grupė yra tylesnė ir kompaktiškesnė (mediana apie 0,05). Analizuojant RMS standartinį nuokrypį stebima ta pati tendencija, rodanti, kad LiveATC įrašai taip pat pasižymi didesniu vidiniu dinamiškumu. Nagrinėjant dinaminio diapazono statistikas matyti, kad LiveATC pavyzdžių medianinis dinaminis diapazonas siekia maždaug 65 dB ir pasižymi didele sklaida bei ekstremaliomis išskirtimis, artėjančiomis prie 175 dB, palyginti su maždaug 45 dB mediana jungtiniame ATCO2/UWB-ATCC duomenų rinkinyje. Tokias ekstremalias dinaminio diapazono reikšmes tikėtina paaiškina reikšmingi tylos intervalai, kurie buvo matomi LiveATC įrašų Mel spektrogramose. Tuo tarpu ATCO2 ir UWB-ATCC duomenys pasižymi gerokai tolygesniais energijos apvalkalais.




5 pav. UWB-ATCC, ATCO2 ir LiveATC įrašų PCA ir t-SNE klasterių diagramos.



6 pav. UWB-ATCC, ATCO2 ir LiveATC įrašų RMS energijos bei dinaminio diapazono stačiakampės diagramos.


Nulinių perėjimų dažnio (ZCR) pasiskirstymai 7 atskleidžia mažiau ryškų skirtumą tarp dviejų duomenų rinkinių nei energijos srities statistiniai rodikliai. Abu šaltiniai pasižymi gana panašiais ZCR pasiskirstymais, rodančiais panašias įgarsinto ir neįgarsinto turinio proporcijas. Pažymėtina, kad padidėję triukšmo lygiai LiveATC įrašuose nesukelia reikšmingo ZCR padidėjimo, lyginant su UWB-ATCC ir ATCO2 duomenų rinkiniais. Tai leidžia daryti išvadą, kad esantys trikdžiai nėra daugiausia plačiajuostis baltasis triukšmas, kuris tikėtinai ženkliai padidintų ZCR, bet veikiau struktūrizuotas triukšmas su spektrine koncentracija tam tikrose dažnių srityse, atitinkantis impulsinius ir intermoduliacinius artefaktus.

Spektrinių požymių pasiskirstymai 8 papildomai apibūdina dažninės srities skirtumus tarp dviejų grupių. ATCO2/UWB-ATCC spektrinis centroidas ryškiai pasiekia maksimumą 600-800 Hz intervale ir tuomet sparčiai mažėja aukštesniuose dažniuose. Tuo tarpu LiveATC pasiskirstymas yra platesnis ir pasislinkęs į aukštesnius dažnius, maksimumą pasiekdamas maždaug 1 000-1 200 Hz intervale. Panaši tendencija stebima ir spektrinio pločio atveju, tai yra abu duomenų rinkiniai maksimumą pasiekia žemų dažnių 200-400 Hz intervale, tačiau LiveATC pasižymi platesne uodega ir antriniu modu ties maždaug 1 000 Hz. Vertinant kartu, šie rezultatai patvirtina, kad ATCO2 ir UWB-ATCC įrašai yra spektriškai kompaktiški ir koncentruoti žemesniame dažnių diapazone, tuo tarpu LiveATC įrašai pasižymi didesniu energijos pasiskirstymu aukštesniuose dažniuose, kurį tikėtinai lemia foninis triukšmas ir perdavimo artefaktai.




7 pav. UWB-ATCC, ATCO2 ir LiveATC įrašų nulio kirtimo dažnio stačiakampės diagramos.

Spektrinių požymių skirstiniai



8 pav. UWB-ATCC, ATCO2 ir LiveATC įrašų spektrinių požymių diagramos.

Akustinė analizė taip pat buvo atlikta sintetintam LibriSpeech rinkiniui, siekiant palyginti jo garso charakteristikas su realiais ATC įrašais. Analizės metu LiveATC, UWB-ATCC ir ATCO2 įrašai buvo sujungti į bendrą grupę. Šio palyginimo tikslas yra įvertinti, koku mastu sintezės procedūra atitinka realių VHF radijo perdavimų akustines charakteristikas, bei nustatyti galimus sisteminius skirtumus, kurie gali paveikti modelio gebėjimą generalizuoti iš sintetintų mokymo duomenų į realias eksploatacines sąlygas. Verta paminėti, kad remiantis šios analizės rezultatais sintezės parametrai buvo iteratyviai keičiami, siekiant kuo tiksliau priartinti sintetintų įrašų charakteristikas prie realių įrašų. Vis dėlto tolimesnėje analizėje pateikiami tik galutinai parinktų parametų intervalų duomenys. Sintetinių duomenų MEL spektrogramas galima matyti 9 grafike.




9 pav. Sintetintų pavyzdinių įrašų Mel spektrogramų diagramos.


Sintetinių bei realių įrašų PCA ir t-SNE projekcijos 10 parodo, kad sintetinti įrašai sudaro kompaktišką ir aiškiai apibrėžtą klasterį, užimantį centrinę realių duomenų pasiskirstymo sritį. Taip pat matyti, kad PC1 paaiškina 85 % visos požymių erdvės dispersijos. Šioje pagrindinėje srityje stebimas reikšmingas abiejų grupių persidengimas, rodantis, kad sintezės grandinė sėkmingai atkuria dominuojančias realių VHF perdavimų akustines charakteristikas. Tačiau pastebėtina, kad realūs įrašai išsiplečia į izoliuotus klasterius, kurių sintetinti duomenys nepasiekia. Tikėtina, kad tai atspindi ekstremalius triukšmo įvykius, segmentus su dideliu tylos kiekiu bei kintamą tylos filtro veikimą. Šios akustinės sąlygos nebuvo modeliuojamos sintezės metu.

Šis įvairovės skirtumas papildomai atsispindi energijos srities statistikų grafikuose 11. Realūs įrašai pasižymi plačiu RMS vidurkio tarpkvartiliniu intervalu, apytiksliai siekiančiu 0,05-0,20 (media-

na apie 0,10). Dinaminis diapazonas apima maždaug 25-100 dB ribas, su ekstremaliomis išskirtimis, artėjančiomis prie 170 dB. Šios išskirtys atitinka amplitudinius šuolius, tylos intervalus ir tylos filtro pereinamuosius procesus, aprašytus ankstesnėje LiveATC analizėje. Lyginant su realiais duomenimis, sintetinti duomenys yra gerokai tolygesni. RMS vidurkio tarpkvartilinis intervalas siekia maždaug 0,05-0,09 (mediana apie 0,06), o dinaminis diapazonas koncentruojasi ties maždaug 20 dB. Šis skirtumas tiesiogiai kyla iš sintezės grandinėje taikomo signalų maišymo metodo. Nuolat maišant kalbą su foniniu triukšmu stochastiškai parinktais lygiais, procedūra generuoja garso signalą su beveik nenutrūkstamai aktyvia energija, todėl neatkuria diskrečių amplitudės perėjimų ir tylos periodų, būdingų realiems VHF signalams.




10 pav. Sintetintų ir tikrų įrašų PCA ir t-SNE klasterių diagramos.




11 pav. Sintetintų ir tikrų įrašų RMS energijos bei dinaminio diapazono stačiakampės diagramos.

Spektrinių požymių pasiskirstymai 13 atskleidžia nuoseklų sintetintų duomenų dažnių poslinkį aukštesnių dažnių kryptimi, lyginant su realiais įrašais. Realų ATC garso įrašų spektrinis centroidas ryškiai koncentruojasi 500-700 Hz diapazone, tuo tarpu sintetinti duomenys pasižymi platesniu ir tolygesniu pasiskirstymu, kuriame reikšminga energijos dalis išlieka 1 000-2 500 Hz intervale, su aiškiai išreikšta antrine moda ties 1 500-2 000 Hz. Atitinkamas skirtumas stebimas ir spektrinio pločio grafike, kuriame sintetinto garso maksimumas pasiekiamas ties maždaug 700-800 Hz, palyginti su 200-400 Hz realiuose įrašuose.

ZCR analizė 12 rodo, kad sintetinti garso segmentai pasižymi sistemiškai didesne medianine ZCR reikšme, maždaug 0,18, lyginant su realiais įrašais, kurių mediana siekia apie 0,12. Šis padidėjimas atspindi tai, kad triukšmo maišymas tolygiai padidina aukštų dažnių energiją visoje garso segmento trukmėje, tuo tarpu realūs įrašai pasižymi natūralesniu kaitaliojimusi tarp žemo ZCR įgarsintos kalbos segmentų ir didesnio ZCR triukšmo segmentų. Apibendrinant, spektrinių požymių ir ZCR analizės rezultatai rodo, kad nors sintezės grandinė generuoja akustiškai tikrovišką garsą bendrąja prasme, ką patvirtina požymių erdvės persidengimas PCA ir t-SNE projekcijose, sintezės grandinė pervertina vidutinių ir aukštų dažnių energiją. Šis skirtumas kyla ne dėl paties kanalo degradacijos modelio trūkumų, bet dėl nuolatinio adityvinio triukšmo maišymo strategijos.




12 pav. Sintetintų ir tikrų įrašų nulio kirtimo dažnio stačiakampės diagramos.




13 pav. Sintetintų ir tikrų įrašų spektrinių požymių diagramos.

Analize taip pat buvo atlikta kiekvienai degradacijos klasei atskirai, siekiant klases palyginti atskirai su apibendrintais realiais ATC įrašais. PCA ir t-SNE projekcijose 14 visos keturios sintetintos klasės Mel požymių erdvėje formuoja glaudžius klasterius, kurie stipriai persidengia tarpusavyje. Ta pati matome ir T-SNE projekcijoje.

RMS energijos statistikos grafike 15 tarp keturių sintetintų klasių stebima nuosekli monotoniška tendencija: blogėjant kanalo sąlygoms vidutinė RMS statistikos nuosekliai mažėja. Tai atspindi vis stipresnį triukšmo poveikį, kuris progresyviai maskuoja pagrindinę kalbos energiją ir suspaudžia efektyvų signalo dinaminį diapazoną. Realūs ATC įrašai (*Tikri*) išlieka gerokai aukščiau visų keturių sintetintų klasių pagal visas tris RMS metrikas, išlaikydami skirtumą tarp realių ir sintetintų duomenų, nustatytą ankstesnėje agreguotoje analizėje.




14 pav. Sintetintų ir tikrų įrašų PCA ir t-SNE klasterių diagramos pagal kokybės klases.




15 pav. Sintetintų ir tikrų įrašų RMS energijos bei dinaminio diapazono stačiakampės diagramos pagal kokybės klases.

ZCR reikšmės 16 didėja nuo *tobulas* klasės link labiau degraduotų klasių, tačiau ties *blogas* klase šiek tiek sumažėja, atspindėdamos netiesinę sąveiką tarp triukšmo lygio ir nulinių kirtimų elgsenos. Tai atitinka ankstesnį pastebėjimą, kad struktūruotas, spektriškai koncentruotas triukšmas nedidina ZCR taip tolygiai, kaip tai darytų plačiajuostis baltasis triukšmas.

Spektriniai požymiai 17 atskleidžia lengviausiai interpretuojamą klasių modelį. Spektrinis centroidas palaipsniui slenka aukštesnių dažnių kryptimi blogėjant kanalo sąlygoms, nuo maždaug 700-900 Hz klasėje *tobulas* iki apie 1 000-1 100 Hz klasėje *blogas*. Tai tiesiogiai atspindi, kaip didėjanti triukšmo energija perkelia spektrinį masės centrą aukštyr VHF pralaidumo juostos ribose. Spektrinis plotis atitinkamai didėja stiprėjant triukšmo sąlygoms. Realūs ATC įrašai išlieka spektriškai žemesni ir siauresni nei visos keturios sintetintos klasės pagal abi metrikas, kas sutampa su anksčiau pateiktais agreguotais analizės rezultatais.



16 pav. Sintetintų ir tikrų įrašų nulio kirtimo dažnio stačiakampės diagramos pagal kokybės klases.



17 pav. Sintetintų ir tikrų įrašų spektrinių požymių diagramos pagal kokybės klases.

3. Metodologija

Kaip buvo matyti duomenų analizės dalyje, realūs VHF įrašai gali pasižymėti drastiškai skirtingomis triukšmo ir akustinėmis charakteristikomis. Nors modernūs kalbos atpažinimo modeliai yra apmokyti naudojant tam tikrą kiekį triukšmingo garso duomenų, tikėtina, kad dėl didelio triukšmo kintamumo modeliai negali vienodai tiksliai generalizuoti visų degradacijos tipų. Tikėtina, kad naudojant specializuotus modelius, pritaikytus specifiniams triukšmo klasteriams, galima pasiekti gerokai aukštesnius rezultatus.

Būtent to ir siekiama šiame darbe. Todėl sintetinių duomenų klasės buvo naudojamos klasifikatoriui apmokyti, kurio išvestis maršrutizuotų įrašą į konkrečiam triukšmo tipui specializuotą modelį, realizuotą naudojant LoRA adapterius. Konkretūs visų modelių apmokymo rezultatai pateikiami šio darbo tiriamojoje dalyje.

3.1. Trukdžių klasifikavimas

Šiame darbe trukdžių klasifikavimui buvo išbandytos trys skirtingos CNN pagrindu sukurtos architektūros:

Pirmoji išbandyta architektūra buvo bazinė CNN architektūra, kuri apdoroja logaritmines Mel spektrogramas naudodama tris konvoliucinius blokus, po kurių taikomas globalus vidurkinis agregavimas (Global Average Pooling, GAP) ir galutinis klasifikatoriaus sluoksnis. Bendra architektūra turi apie 500 tūkst. apmokomų parametrų. Nors ši architektūra sąmoningai išlaikyta paprasta, ji naudojama kaip bazinis modelis, su kuriuo lyginami sudėtingesni modeliai.

Antroji išbandyta architektūra buvo konvoliucinis rekurentinis neuroninis tinklas (Convolutional Recurrent Neural Network, CRNN), jungiantis dviejų sluoksnių konvoliucinį bloką, skirtą lokalių požymių išgavimui, su dvikrypčiu sklendinių rekurentinių vienetų (BiGRU) sekų modeliu. Ši architektūra turi apie 1,5 mln. parametrų. Konvoliuciniai sluoksniai taiko agregavimą tik dažnių ašies kryptimi, išsaugodami pilną laiko dimensiją rekurentiniam etapui. Tai leidžia modeliui užfiksuoti laiko atžvilgiu kintančias degradacijos charakteristikas, tokias kaip signalo slopinimas ir impulsinio triukšmo evoliucija, kuriuos globalus vidurkinis agregavimas kitu atveju pašalintų.

Trečioji išbandyta architektūra buvo ECAPA-TDNN [4] (Emphasized Channel Attention, Propagation and Aggregation Time Delay Neural Network). Šis modelis dažniausiai naudojamas kalbėtojų klasifikavimo užduotims, tačiau jis geba klasifikuoti įvairius garso požymius. Modelis naudoja SE-Res2Net blokus su daugiamačio mastelio praretintomis konvoliucijomis (angl. dilated convolution) ir suspaudimo-jaudinimo (angl. squeeze-excitation) kanalų dėmesio mechanizmu, po kurių taikomas dėmesiu grįstas statistinis agregavimas (angl. attentive statistical pooling). Bendra architektūra turi apie 6 mln. parametrų. Ši architektūra geba vieningoje sistemoje užfiksuoti tiek smulkios struktūros spektrinius požymius, tiek ilgalaikes degradacijos charakteristikas laiko dimensijoje.

8 lentelė. Vertintų klasifikavimo architektūrų santrauka.

Modelis	Pagrindinė architektūra	Parametrų sk.
CNN (bazinis)	3× Conv2D + GAP	~500K
CRNN	2× Conv2D + BiGRU	~1.5M
ECAPA-TDNN	SE-Res2Net + dėmesio agregavimas	~6M

3.2. LoRA adapteriai

Kaip ir buvo minėta literatūros apžvalgoje, LoRA ir PEFT yra E2E modelių mokymo metodai, kuriais siekiama aproksimuoti bendro modelio mokymo metu atnaujinamus parametrus. Šių metodų pagrindinė idėja yra ta, kad iš anksto apmokyto modelio pritaikymui artimai sričiai nereikia reikšmingai keisti visos parametrų aibės – pakanka atnaujinti tik nedidelę dalį parametrų. Šių metodų metu iš anksto apmokyto modelio parametrai yra užšaldomi, o į pasirinktus modelio sluoksnius integruojama nedidelė naujų parametrų aibė, kuri yra apmokoma tolimesnio mokymo metu. Tokia aproksimacija gali būti išreiškiama kaip:

$$W'_Q = W_Q + A_Q B_Q, \quad W'_V = W_V + A_V B_V \quad (17)$$

kur $W_Q, W_V \in \mathbb{R}^{d \times d}$ žymi užšaldytas bazinio modelio projekcijų svorių matricas, o $A_Q, A_V \in \mathbb{R}^{d \times r}$ – LoRA svorių matricas, atsakingas už projekciją į žemesnės dimensijos erdvę. Tuo tarpu $B_Q, B_V \in \mathbb{R}^{r \times d}$ apibrėžia matricas, kurios transformuoja projekciją atgal į pradinę erdvę. Čia $r \ll d$ yra rango hiperparametras, nusakantis apmokamų parametrų skaičių. Galiausiai, W'_Q ir W'_V žymi galutines svorių matricas, apimančias tiek pradinio modelio informaciją, tiek adaptuotą pokytį $\Delta W = AB$.

Mokymo pradžioje matricos B yra inicializuojamos nuliais, todėl $\Delta W = AB = 0$. Dėl šios priežasties pradinė modelio elgsena išlieka nepakitusi, o adaptacija vyksta palaipsniui mokymo proceso metu. Po sėkmingo apmokymo modelis išlaiko pradinio mokymo metu įgytas žinias, tačiau jo išvestys tampa geriau pritaikytos specifinėms sritims, kuriose turima tik nedidelis kiekis duomenų.

Įprastai LoRA adapteriai yra naudojami modelio pritaikymui visai duomenų aibei, tačiau šiame darbe jie taikomi kaip atskiri specializuoti modeliai, apmokyti transkribuoti kalbą esant konkrečiam triukšmo tipui. Nors ši idėja literatūroje plačiai nenagrinėta, teoriškai ji galėtų leisti modeliui prioritetizuoti tam tikrus parametrus specifinėms akustinės degradacijos charakteristikoms, vietoj to, kad vienas modelis stengtųsi vienodai gerai apdoroti visą degradacijos spektrą. Tokiu būdu kiekvienas adapteris galėtų specializuotis siauresnėje akustinių sąlygų erdvėje, o tai teoriškai sumažintų modelio vidinę variaciją ir pagerintų transkribavimo tikslumą konkrečiai triukšmo klasei, kuriai adapteris buvo apmokytas.

3.3. Žodžio klaidos metrika

Taip pat vertėtų paminėti, kad šiame darbe, kaip ir kalbos atpažinimo srityje apskritai, dažnai naudojama žodžių klaidos metrika (WER), kuri nusako, kaip tiksliai modelis geba transkribuoti garso įrašą į tekstą. Ši metrika apibrėžiama taip:

$$\text{WER} = \frac{S + D + I}{N} \quad (18)$$

kur S — pakeistų žodžių skaičius (angl. *substitutions*), D — nebūtų žodžių skaičius (angl. *deletions*), I — įterptų žodžių skaičius (angl. *insertions*), N — bendras žodžių skaičius (angl. *reference*).

4. Tiriemoji-analizė

4.1. Trukdžių klasifikavimas

Sintetinti garso įrašai ir juos atitinkančios kanalo kokybės klasių žymės buvo naudojami kanalo kokybės klasifikatoriui apmokyti. Keturių klasių VHF kanalo kokybės klasifikavimo užduočiai buvo vertinamos trys CNN pagrindu sukurtų modelių architektūros. Visi modeliai buvo apmokyti 20 epochų.

9 lentelė. Klasifikavimo modelių suvestinė.

Modelis	Treniravimas		Validavimas		Testavimas	
	Tikslumas	Macro-F1	Tikslumas	Macro-F1	Tikslumas	Macro-F1
CNN	0,9711	0,9710	0,9752	0,9752	0,9741	0,9741
CRNN	0,9939	0,9939	0,9874	0,9874	0,9885	0,9885
ECAPA-TDNN	0,9927	0,9927	0,9883	0,9883	0,9892	0,9892

Klasifikavimo rezultatai rodo, kad visos trys architektūros sintetintame duomenų rinkinyje pasiekia beveik tobulą tikslumą, o tai atspindi nuoseklų ir tvarkingą akustinį gradientą tarp degradacijos klasių. Skirtumai tarp modelių klasifikavimo tikslumo yra minimalūs. Nepaisant to, ECAPA-TDNN buvo pasirinktas kaip LoRA adapterių sistemos maršrutizavimo klasifikatorius, nes jo dėmesiu grįstas statistinis agregavimas (angl. attentive statistical pooling) ir daugiamačio mastelio laikinis modeliavimas suteikia didžiausią reprezentacinį pajėgumą subtiliems degradacijos skirtumams užfiksuoti, kurie gali tapti svarbūs klasifikatorių taikant realiems VHF įrašams.

10 lentelė. ECAPA-TDNN klasifikavimo ataskaita

Klasė	Treniravimas			Validavimas			Testavimas		
	P	R	F1	P	R	F1	P	R	F1
Tobulas	1,00	1,00	1,00	0,99	1,00	1,00	0,99	1,00	1,00
Geras	0,99	1,00	1,00	0,99	0,99	0,99	0,99	0,99	0,99
Vidutinis	0,99	0,99	0,99	0,98	0,98	0,98	0,98	0,99	0,98
Blogas	0,99	0,99	0,99	0,99	0,98	0,99	0,99	0,98	0,99

Prieš apmokant individualius LoRA adapterius kiekvienai trukdžių klasei, realiems anotuotiems ATC įrašams turi būti priskirtos kanalo kokybės pseudožymos. Kadangi šiems korpusams nėra prieinamų tikru degradacijos žymių, kiekvienam įrašui klasė nustatoma taikant apmokytą ECAPA-TDNN klasifikatorių, kuris priskiria įrašą pagal prognozuotą kanalo kokybės klasę. Šios pseudožymės vėliau buvo naudojamos realių anotuotų duomenų suskirstymui į nuo klasės priklausančius poaibius, kurių kiekvienas naudojamas atitinkamo LoRA adapterio apmokymui.

ECAPA-TDNN prognozių pasiskirstymas realiuose anotuotuose įrašuose pateiktas lentelėje 11. Klasifikatorius didžiąjai daugumai pavyzdžių (6 170 iš 6 497) priskiria *tobula* klasę, o kiekvienoje labiau

degraduotoje klasėje pavyzdžių skaičius palaipsniui mažėja. Dėl susidariusio ryškaus klasių disbalanso *geroms*, *vidutinėms* ir *blogoms* sąlygoms skirti LoRA adapteriai bus apmokomi naudojant gerokai mažesnę realių anotuotų duomenų kiekį, todėl tai yra svarbus aspektas interpretuojant skirtingų klasių adaptuotų modelių našumo rezultatus.

11 lentelė. ECAPA-TDNN klasifikavimo rezultatai realiuose ATC įrašuose.

Klasė	Įrašų skaičius
Tobulas	6 170
Geras	171
Vidutinis	129
Blogas	27
Iš viso	6 497

4.2. LoRA Adapteriai

Kiekvienai garso kokybės klasei (*tobulas*, *geras*, *vidutinis*, *blogas*) buvo apmokytas atskiras LoRA adapteris, naudojant užšaldytą OpenAI Whisper-Small bazinį modelį. LoRA konfigūracijoje buvo taikytas rango parametras $r = 16$, mastelio koeficientas $\alpha = 32$ ir išmetimo tikimybė $p = 0.05$. Adapteriai buvo pritaikyti transformerio užklauso, reikšmės, išvesties projekcijos bei pilnai sujungtų sluoksnių komponentams (q_proj , v_proj , out_proj , $fc1$, $fc2$). Dėl to kiekvienas adapteris turėjo 5 603 328 apmokomus parametrus, sudarančius maždaug 2,27 % visų modelio parametrų. Tokia konfigūracija leido išlaikyti nedidelį atminties ir skaičiavimų poreikį, kartu suteikiant galimybę prasmingai adaptuoti modelį skirtingoms triukšmo sąlygoms.

Kiekvienas adapteris buvo apmokytas 5 epochas naudojant AdamW optimizatorių su mokymosi žingsniu 1×10^{-4} , svorių mažinimo koeficientu 1×10^{-2} bei tiesiniu įšilimu per pirmuosius 10% visų mokymo žingsnių, po kurio buvo taikomas tiesinis mažėjimas. Gradientų akumuliacija per 4 žingsnius buvo naudojama siekiant simuliuoti didesnę efektyvų 32 dydžio duomenų rinkiniui (angl. batch). Mokymas buvo vykdomas naudojant bfloat16 tikslumą ir aktyvuotą gradientų kontrolinių taškų mechanizmą (*gradient checkpointing*), siekiant sumažinti VRAM atminties sąnaudas.

Modelio atranka buvo grindžiama žodžių klaidos rodikliu (WER) validavimo rinkinyje. Efektyvumo sumetimais validavimas buvo atliekama du kartus per epochą naudojant 750 pavyzdžių poaibį, o kiekvienos epochos pabaigoje papildomai vertinama naudojant visą validavimo rinkinį. Geriausias kontrolinis taškas pagal validavimo WER buvo išsaugotas kaip galutinis atitinkamos sąlygos adapteris.

Svarbu pažymėti, kad mokymo metu kiekvienam garso pavyzdžiui priskirtos sąlygų žymės buvo naudojamos tiesiogiai tokios, kokias pateikė duomenų rinkinio simuliacijos grandinė, papildomas peržymėjimas ar verifikacija mokymo metu nebuvo atliekami. Sąlygų žymės buvo sugeneruotos remiantis tik simuliuota akustine degradacija, pritaikyta garso signalui duomenų rinkinio sudarymo metu. Tai reiškia, kad žymės atspindi žinomus degradacijos parametrus, o ne prognozuotą klasifikavimo rezultatą.

Vertinant nežymėtus duomenų rinkinius, kuriuose nebuvo prieinamų tikrinių sąlygų žymių, visi pavyzdžiai prieš transkripciją buvo automatiškai sužymėti naudojant ECAPA-TDNN klasifikatorių. Prognozuota sąlygos žymė tuomet buvo naudojama atitinkamam LoRA adapteriui parinkti, taip sudarant pilną anksčiau aprašytą generavimo grandinę.

Taip pat analizės metu buvo apmokytas nesąlygotas LoRA adapteris, naudojant visą duomenų aibę, jos neskirstant į atskiras triukšmo kategorijas. Šis modelis buvo naudojamas siekiant įvertinti, ar įrašų skaidymas pagal triukšmo pseudoklases ir atskirų specializuotų modelių taikymas iš tiesų pagerina rezultatus, ar geresnius rodiklius galima pasiekti tiesiog apmokant modelį visa duomenų aibe.

Sukurtai sistema — Whisper-Small modelis su sąlygotais LoRA adapteriais, kurių parinkimą vykdo ECAPA-TDNN klasifikatorius — pasiekia reikšmingą WER sumažėjimą, lyginant su nemodifikuotais Whisper baziniais modeliais. LibriSpeech testavimo rinkinyje WER sumažėja nuo 67,36 % iki 26,87 %. Rezultatų analizė pagal atskiras sąlygas rodo, kad modelio našumas blogėja nuosekliai mažėjant garso kokybei. *Tobuloje* klasėje pasiekiamas 9,78 % WER LibriSpeech rinkinyje, tuo tarpu *blogoje* klasėje rodiklis padidėja iki 51,76 %, atspindėdamas sudėtingą stipriai degraduotos VHF kalbos atpažinimo pobūdį. Lyginant sąlygotus ir nesąlygotą LoRA adapterius, matyti, kad bent jau visose LibriSpeech duomenų aibėse modelių rezultatai reikšmingai nesiskiria.

12 lentelė. Bazinių modelių žodžių klaidos dažnis (WER) pagal duomenų rinkinį.

Modelis	Mokymo WER (%)	Validavimo WER (%)	Testavimo WER (%)
Whisper-Small (bazinis)	78,30	66,03	67,36
Whisper-Small + nesąl. LoRA	18,44	26,57	26,94
Whisper-Small + sąl. LoRA	18,06	26,77	26,87

13 lentelė. Whisper Small + sąl. LoRA adapteriai: WER pagal kokybės klasę.

Kokybės klasė	LibriSpeech validavimo aibė		LibriSpeech testavimo aibė		ATC testavimo aibė	
	Imtys	WER (%)	Imtys	WER (%)	Imtys	WER (%)
Tobulas	6 348	9,52	6 356	9,78	780	14,62
Geras	5 587	16,45	5 568	16,79	17	83,23
Vidutinis	5 607	31,42	5 625	30,69	15	40,59
Blogas	5 538	51,10	5 500	51,76	1	225,00
Iš viso	23 080	26,77	23 049	26,87	813	16,58

UWB-ATCC/ATCO2 testavimo rinkinyje sistema pasiekia 16,58 % WER. Tai yra ganėtinai konkurencingas rezultatas, lyginant su specializuotais modeliais, apmokytais išskirtinai naudojant ATC duomenis. Sukurta sistema daugiau nei 21 % punktu lenkia aether-raid/astra-atc-models bei reikšmingai pranoksta abu nemodifikuotus bazinius modelius. Lyginant su jacktol/whisper-large-v3-finetuned-for-ATC modeliu, sukurta sistema atsilieka 9,65 % punkto. Toks rezultatas nėra ste-

binantis, kadangi šis modelis yra maždaug 6,4 karto didesnis bei buvo išskirtinai apmokytas naudojant UWB-ATCC ir ATCO2 duomenų rinkinius. Lyginant sukurta sistemą su nesąlyginiu LoRA adapteriu, matyti, kad sukurta sistema jį lenkia 5,76 % punkto. Tai rodo, kad bent jau realiųjų ATC duomenų rinkinyje sukurta modelis geba tiksliau atpažinti kalbą.

14 lentelė. *Lyginamieji modeliai ATC ASR testavimo rinkinyje (813 imčių).*

Modelis	Tipas	WER (%)
jacktol/whisper-large-v3-finetuned-for-ATC	Specialusis	6,93
Whisper Small + sąlyginiai LoRA adapteriai	Specialusis	16,58
Whisper Small + nesąlyginiai LoRA adapteriai	Specialusis	22,34
aether-raid/astra-atc-models	Specialusis	37,22
Whisper Large v3 (bazinis)	Bazinis	83,23
Whisper Small (bazinis)	Bazinis	93,61

Kadangi ECAPA-TDNN modelis gana nebalansuotai priskyrė pseudožymių klases realiaame ATC duomenų testavimo rinkinyje, buvo rankiniu būdu anotuoti apie 33 įrašai (apie 12 min.) duomenų, atrinktų iš LiveATC duomenų rinkinio. Įrašai buvo parinkti taip, kad maždaug atitiktų subalansuotą degradacijos lygių pasiskirstymą pagal klases. Tačiau, kaip matyti toliau pateiktose lentelėse, įrašų pasiskirstymas vis tiek išliko nebalansuotas, o tai rodo, kad klasifikavimo modelis galimai prastai generalizuoja nematytiems duomenims. Toks generalizavimo trūkumas tikėtina kyla dėl pernelyg siaurai parinktų simuliuotų duomenų parametrų.

Žvelgiant į rezultatus, gautus naudojant ranka anotuotus realius duomenis, matyti, kad visi specializuoti modeliai pasirodo gana prastai. Šiame darbe sukurta architektūra pasiekia agreguotą 68,84 % WER rodiklį, jacktol/whisper-large-v3-finetuned-for-ATC modelis pasiekia 43,41 %, o aether-raid/astra-atc-models — 71,53 %. Taip pat matyti, kad nesąlygotas adapteris pasirodė prasčiau – jo pasiektas WER siekė 73,16 %. Tai rodo, kad anksčiau nematytų VHF duomenų garso charakteristikos stipriai skiriasi nuo mokymo metu matytų pavyzdžių, todėl modelių gebėjimas generalizuoti yra ribotas. Taip pat verta paminėti, kad įrašuose gausu specifinių vietovardžių ir geografinių pavadinimų, kurie tikėtina nebuvo įtraukti į modelių mokymo aibes, o tai papildomai blogina transkribavimo tikslumą.

Apibendrinant, šie rezultatai rodo, kad sąlygoms jautrus adapterių maršrutizavimas gali suteikti reikšmingą pranašumą prieš vieną bendros paskirties modelį, ypač esant akustinei degradacijai. Taip pat, lyginant sąlyginius ir nesąlygotą LoRA adapterius, matyti, kad nors abu modeliai LibriSpeech duomenų rinkinyje pasirodė labai panašiai, realiuose duomenyse aiškiai matoma, jog sąlyginis triukšmo maršrutizavimas leido bendrai sistemai geriau generalizuoti nematytiems duomenims. Tačiau tikėtina, kad siekiant pasiekti dar geresnius rezultatus reikėtų apimti platesnį garso degradacijos spektrą, nei buvo nagrinėta šiame darbe.

15 lentelė. Sąlyginių LoRA adapterių WER rodikliai pagal garso kokybės klasę mažoje testavimo imtyje.

Klasė	Imtys	WER (%)
Tobulas	22	63,46
Geras	2	69,77
Vidutinis	3	91,57
Blogas	6	76,10
Viso	33	68,84

16 lentelė. Lyginamieji modeliai mažame testavimo rinkinyje (33 imtys).

Modelis	Tipas	WER (%)
jacktol/whisper-large-v3-finetuned-for-ATC	Specialusis	43,41
Whisper Small + sąlyginiai LoRA adapteriai	Specialusis	68,84
aether-raid/astra-atc-models	Specialusis	71,53
Whisper Small + nesąlyginiai LoRA adapteriai	Specialusis	73,16

5. Išvados ir rekomendacijos

Sukurta kalbos atpažinimo sistema pademonstravo stiprius rezultatus visuose vertintuose duomenų rinkiniuose. Sintetintame LibriSpeech testavimo rinkinyje sąlygoms pritaikytų LoRA adapterių sistema sumažino WER rodiklį nuo 67,36 % iki 26,87 %, lyginant su nemodifikuotu Whisper-Small baziniu modeliu. *Tobuloje* klasėje buvo pasiektas 9,78 % WER, o *blogoje* klasėje rodiklis padidėjo iki 51,76 %, atspindėdamas tikėtiną degradacijos gradientą. Tame pačiame duomenų rinkinyje sukurta sistema rezultatų prasme reikšmingai nesiskyrė nuo nesąlygoto LoRA adapterio modelio.

Realiam ATC testavimo rinkinyje sistema pasiekė 16,58% agreguotą WER rezultatą, atsilikdama 9,78 %² punkto nuo `jacktol/whisper-large-v3-finetuned-for-ATC` modelio, kuris yra maždaug 6,4 karto didesnis. Tuo pačiu sistema daugiau nei 21 % punktu pranoko `aether-raid/astra-atc-models`, 5,76 % punkto pranoko nesąlygotą LoRA adapterį bei reikšmingai aplenkė abu nemodifikuotus bazinius modelius. Testuojant visus specializuotus modelius naudojant nematytus ranka anotuosius įrašus, buvo stebima stipri rezultatų degradacija, rodanti, kad visi modeliai sunkiai geba generalizuoti nematytoms (OOD) garso charakteristikoms bei specifinei terminijai.

Duomenų sintezės grandinė, sukurta naudojant GNU Radio pagrindu veikiančią VHF AM kanalo simuliaciją, sėkmingai sugeneravo didelės apimties mokymo duomenų rinkinį, aproksimuojantį realias aviacijos radijo kanalo charakteristikas. Tai buvo patvirtinta akustine analize, kuri parodė reikšmingą požymių erdvės persidengimą tarp sintetintų ir realių įrašų.

ECAPA-TDNN klasifikatorius sintetintame testavimo rinkinyje pasiekė beveik tobulą 98-99% maršrutizavimo tikslumą, tačiau gana nebalansuotai klasifikavo nematytus realius duomenis, kas galimai rodo pernelyg siaurą duomenų sintezės parametrų parinkimą bei nepakankamą sintetintų duomenų įvairovę.

Apibendrinant, šie rezultatai rodo, kad garso įrašo degradacijos lygio adapterių maršrutizavimas, naudojant kompaktišką bazinį modelį, yra perspektyvus ir efektyvus metodas patikimam kalbos atpažinimui kintančios VHF kanalo degradacijos sąlygomis.

Ateityje rekomenduojama tyrimą papildyti platesniu duomenų sintezės parametrų parinkimu. Taip pat siūloma neapsiriboti specifinių garso charakteristikų klasių kūrimu, o pseudožymas modeliuoti kaip modelių parinktus klasterius. Be to, į sintezuotą duomenų rinkinį vertėtų inkorporuoti daugiau ICAO terminologiją atspindinčios kalbos. Tokie darbo papildymai tikėtina pagerintų maršrutizavimo kokybę bei leistų geriau generalizuoti nematytiems duomenims. Taip pat vertėtų išanalizuoti alternatyvius LoRA adapterių išdėstymo būdus bei kitus kalbos atpažinimo modelius.

²Kadangi klasifikavimo modelis nematytus realius ATC duomenis suskirstė labai nebalansuotai, ypač blogos kokybės klasei priskirdamas tik vieną įrašą, bendruosius rezultatus reikėtų vertinti atsargiai.

Literatūra ir šaltiniai

- [1] P. A. Bello. „Characterization of Randomly Time-Variant Linear Channels“. Iš: *IEEE Transactions on Communication Systems* 11.4 (1963), puslapiai 360–393. <https://doi.org/10.1109/TCOM.1963.1088793>.
- [2] D. Biderman, J. Portes, J. J. Gonzalez Ortiz, M. Paul ir kiti. „LoRA Learns Less and Forgets Less“. Iš: *Transactions on Machine Learning Research* (2024). URL: <https://openreview.net/forum?id=aloEru2qCG>.
- [3] L. Boegner, M. Gulati, G. Vanhoy, P. Vallance, B. Comar, S. Kokalj-Filipovic, C. Lennon, R. D. Miller. *Large Scale Radio Frequency Signal Classification*. 2022. URL: <https://arxiv.org/abs/2207.09918>.
- [4] B. Desplanques, J. Thienpondt, K. Demuynck. „Ecapa-tdnn: Emphasized channel attention, propagation and aggregation in tdnn based speaker verification“. Iš: *arXiv preprint arXiv:2005.07143* (2020).
- [5] J. van Doorn, J. Sun, J. M. Hoekstra, P. Jonk, V. de Vries. „Whisper-ATC: Open Models for Air Traffic Control Automatic Speech Recognition“. Iš: *Proceedings of the International Conference on Research in Air Transportation (ICRAT 2024)*. 2024.
- [6] Freesound Community. *Freesound*. <https://freesound.org>. 2024.
- [7] E. Haas. „Aeronautical Channel Modeling“. Iš: *IEEE Transactions on Vehicular Technology* 51.2 (2002), puslapiai 254–264. <https://doi.org/10.1109/25.994803>.
- [8] H. Helmke, M. Kleinert, S. Shetty, O. Ohneiser ir kiti. „Readback Error Detection by Automatic Speech Recognition to Increase ATM Safety“. Iš: *Proceedings of the 14th USA/Europe Air Traffic Management Research and Development Seminar (ATM2021)*. Virtual: EUROCONTROL, 2021, puslapiai 1–10.
- [9] N. Houlsby, A. Giurgiu, S. Jastrzebski, B. Morrone, Q. De Laroussilhe, A. Gesmundo, M. Attariyan, S. Gelly. „Parameter-Efficient Transfer Learning for NLP“. Iš: *Proceedings of the 36th International Conference on Machine Learning (ICML)*. Tomas 97. *Proceedings of Machine Learning Research*. 2019, puslapiai 2790–2799. URL: <https://proceedings.mlr.press/v97/houlsby19a.html>.
- [10] International Civil Aviation Organization. *Manual of Radiotelephony*. 4th. Doc 9432. ICAO. Montreal, 2007.
- [11] International Civil Aviation Organization. *Aeronautical Telecommunications, Annex 10 to the Convention on International Civil Aviation, Volume II: Communication Procedures*. 7th. ICAO. Montreal, 2016.
- [12] ITU-R Study Group 1. *Recommendation ITU-R P.372-16: Radio Noise*. Techninė ataskaita. Geneva: International Telecommunication Union, 2022.

- [13] ITU-R Study Group 3. *Recommendation ITU-R P.528-5: A Propagation Prediction Method for Aeronautical Mobile and Radionavigation Services Using the VHF, UHF and SHF Bands*. Techninė ataskaita. Geneva: International Telecommunication Union, 2021.
- [14] J. Li, L. Deng, Y. Gong, R. Haeb-Umbach. „An Overview of Noise-Robust Automatic Speech Recognition“. Iš: *IEEE/ACM Transactions on Audio, Speech, and Language Processing* 22.4 (2014), puslapiai 745–777. <https://doi.org/10.1109/TASLP.2014.2304637>.
- [15] LiveATC.net. *Live Air Traffic Control Audio Feeds*. <https://www.liveatc.net>.
- [16] D. Middleton. „Canonical and Quasi-Canonical Probability Models of Class A Interference“. Iš: *IEEE Transactions on Electromagnetic Compatibility* 25.2 (1983), puslapiai 76–106. <https://doi.org/10.1109/TEMC.1983.304151>.
- [17] nyuuzyou. *LiveATC Dataset*. <https://huggingface.co/datasets/nyuuzyou/liveatc>. 2024.
- [18] T. J. O’Shea, T. Roy, T. C. Clancy. „Over-the-Air Deep Learning Based Radio Signal Classification“. Iš: *IEEE Journal of Selected Topics in Signal Processing* 12.1 (2018), puslapiai 168–179. <https://doi.org/10.1109/JSTSP.2018.2797022>.
- [19] V. Panayotov, G. Chen, D. Povey, S. Khudanpur. „LibriSpeech: An ASR Corpus Based on Public Domain Audio Books“. Iš: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. 2015, puslapiai 5206–5210. <https://doi.org/10.1109/ICASSP.2015.7178964>.
- [20] K. J. Piczak. „ESC: Dataset for Environmental Sound Classification“. Iš: *Proceedings of the 23rd ACM International Conference on Multimedia*. Brisbane, Australia: ACM Press, 2015, puslapiai 1015–1018. <https://doi.org/10.1145/2733373.2806390>.
- [21] J. G. Proakis. *Digital Communications*. 5th. New York: McGraw-Hill, 2008.
- [22] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, I. Sutskever. „Robust Speech Recognition via Large-Scale Weak Supervision“. Iš: *Proceedings of the 40th International Conference on Machine Learning (ICML)*. 2023, puslapiai 28492–28518. URL: <https://arxiv.org/abs/2212.04356>.
- [23] T. S. Rappaport. *Wireless Communications: Principles and Practice*. 2nd. Upper Saddle River, NJ: Prentice Hall, 2002.
- [24] H. Shi, T. Kawahara. *Exploration of Adapter for Noise Robust Automatic Speech Recognition*. 2024. URL: <https://arxiv.org/abs/2402.18275>.
- [25] Z. Song, J. Zhuo, Y. Yang, Z. Ma, S. Zhang, X. Chen. „LoRA-Whisper: Parameter-Efficient and Extensible Multilingual ASR“. Iš: *Proceedings of Interspeech 2024*. 2024, puslapiai 3934–3938. <https://doi.org/10.21437/Interspeech.2024-892>.
- [26] Spanish Ministerio de Transportes y Comunicaciones. *Report on the Accident to Boeing 747 Aircraft PH-BUF of KLM and N736PA of Pan Am at Los Rodeos Airport, Tenerife, on 27 March 1977*. Techninė ataskaita. Madrid: Ministerio de Transportes y Comunicaciones, 1978.

- [27] J. Suu ir kiti. *Fine-Tuning Whisper for American English Air Traffic Control Speech Recognition: A Data-Efficient Pipeline*. Research Square preprint. 2026. URL: <https://www.researchsquare.com/article/rs-8970162/v1>.
- [28] Y. Wang, A. Alhmoud, S. Alsahly, M. Alqurishi, M. Ravanelli. *Calm-Whisper: Reduce Whisper Hallucination on Non-Speech by Calming Crazy Heads Down*. 2025. URL: <https://arxiv.org/abs/2505.12969>.
- [29] Z. Wang, P. Jiang, Z. Wang, B. Han, H. Liang, Y. Ai, W. Pan. „Enhancing Air Traffic Control Communication Systems with Integrated Automatic Speech Recognition: Models, Applications and Performance Evaluation“. Iš: *Sensors* 24.14 (2024), puslapis 4715. <https://doi.org/10.3390/s24144715>.
- [30] M. Y. Z. Wee, J. J. H. Wong, L. Lim, J. Y. W. Tan, P. Gupta, D. Lim, E. H. Tew, A. K. S. Han, Y. Z. Lim. *Adapting Automatic Speech Recognition for Accented Air Traffic Control Communications*. 2025. URL: <https://arxiv.org/abs/2502.20311>.
- [31] J. Zuluaga-Gomez. *UWB-ATCC Corpus*. Hugging Face Datasets. 2022. URL: https://huggingface.co/datasets/Jzuluaga/uwb_atcc.
- [32] J. Zuluaga-Gomez, K. Veselý, I. Szöke, P. Motlicek ir kiti. *ATCO2 Corpus: A Large-Scale Dataset for Research on Automatic Speech Recognition and Natural Language Understanding of Air Traffic Control Communications*. 2022. URL: <https://arxiv.org/abs/2211.04054>.

6. Priedas

6.1. Dirbtinio intelekto naudojimas darbe

Šiame darbe dirbtinis intelektas buvo naudojamas kaip įrankis kodo generavimui, teksto formatavimui bei kaip paieškos sistema. Darbo idėjos ir metodologija buvo sugalvotos savarankiškai, tačiau dirbtiniu intelektu pasinaudota kaip pagalbine priemone, įgyvendinimo specifikai tikslinti ir idėjoms validuoti. Naudojami dirbtinio intelekto įrankiai ir jų paskirtys:

1. Claude - Naudojama kaip paieškos sistema, tam tikro kodo generavimui, bei lentelių generavimo įrankis (naudojant gautas metrikas).
2. ChatGPT - Naudojama teksto formatavimui bei klaidų taisymui.
3. Google Gemini - Naudojama tam tikrų terminų vertimui.

Pavyzdinės užklausos:

- „I will provide you with specific english terms in the context of ..., you must find correct translations for these terms to Lithuanian“.
- „I will provide you with Lithuanian academic text, your job is to find and mark places where grammatical mistakes were made“.
- „Based on the following data create a latex table, output in code block:“.
- „What is Doppler effect and how can it be seen in radiotelecommutation voice channels?“.


6.2. Trukdžių Klasifikavimas

17 lentelė. CNN klasifikavimo ataskaita.

Klasė	Treniravimas			Validavimas			Testavimas		
	P	R	F1	P	R	F1	P	R	F1
Tobulas	0,99	0,99	0,99	0,99	0,99	0,99	0,98	0,99	0,99
Geras	0,96	0,98	0,97	0,97	0,98	0,98	0,97	0,98	0,98
Vidutinis	0,96	0,94	0,95	0,97	0,96	0,96	0,97	0,96	0,96
Blogas	0,97	0,97	0,97	0,98	0,97	0,97	0,97	0,97	0,97


18 lentelė. CRNN klasifikavimo ataskaita.

Klasė	Treniravimas			Validavimas			Testavimas		
	P	R	F1	P	R	F1	P	R	F1
Tobulas	1,00	1,00	1,00	1,00	0,99	1,00	1,00	1,00	1,00
Geras	1,00	1,00	1,00	0,99	0,99	0,99	0,99	0,99	0,99
Vidutinis	0,99	0,99	0,99	0,98	0,98	0,98	0,98	0,99	0,98
Blogas	0,99	0,99	0,99	0,99	0,98	0,98	0,99	0,98	0,98




18 pav. Trukdžių kategorijų klasifikavimo modelių mokymo ir validavimo nuostolių bei tikslumo grafikai.

6.3. LoRA Adapteriai




19 pav. Tobulos trukdžių klasės LoRa adapterio nuostolių ir WER grafikai.

LoRa adapteris klasei: Geras




20 pav. Geros trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.

LoRa adapteris klasei: Vidutinis



21 pav. Vidutinės trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.

LoRa adapteris klasei: Blogas



22 pav. Blogos trukdžių klasės LoRA adapterio nuostolių ir WER grafikai.

19 lentelė. *Whisper Small + nesql. LoRA adapteris: WER pagal kokybės klasę.*

Kokybės klasė	LibriSpeech mokymo aibė		LibriSpeech validavimo aibė		LibriSpeech testavimo aibė		ATC testavimo aibė	
	Imtys	WER (%)	Imtys	WER (%)	Imtys	WER (%)	Imtys	WER (%)
Tobulas	13 238	7,98	6 336	9,52	6 339	9,70	—	—
Geras	7 227	9,18	5 584	16,35	5 576	16,76	—	—
Vidutinis	7 190	19,58	5 586	30,36	5 574	30,71	—	—
Blogas	7 187	39,51	5 574	51,33	5 560	51,93	—	—
Iš viso	34 842	18,44	23 080	26,57	23 049	26,94	813	22,34